

목차

PORTFOLIO · 김단비 · BACKEND

01

COVER

커버 — Portfolio 메인

02

01 · EXPERIENCE

실무 경력 — 2년의 운영 오너십

03

02 · PROJECT

프로젝트 #1 — 다2조부르릉

04

03 · PROJECT

프로젝트 #2 — ants-camp

05

04 · CAPABILITY

AI 워크플로우 — 하네스 엔지니어링

운영에서 시작해 LLMOps까지 정합성·신뢰성을 설계하는 백엔드.

회원제 SaaS 운영팀에서 **RDBMS** 마이그레이션·동시성 제어·다국가 확장을 직접 풀어내고,
그 한계에서 공부할 이유를 찾아 **모놀리식** → **MSA** → **LLMOps**까지 설계 경험을 단계적으로 확장했습니다.
"왜 이 기술을 쓰는가"를 끝까지 묻고, 운영 환경의 정합성·신뢰성 문제를 설계 단계에서 해결합니다.

● github.com/danbeekimm ● velog.io/@danbeekimm ▶ [ants-camp 라이브 데모](#) ▶ [다2조부르릉 라이브 데모](#)

WORKS

프로젝트 · 경력

세 작업을 시간순으로. 실무에서 출발해 모놀리식·MSA를 거쳐 LLMOps에 닿은 궤적 — 현장에서 마주친 한계를 학습 동기로 삼아, 다음 프로젝트의 설계 결정까지 이어 간 흐름.

📁 EXPERIENCE · 실무 경력

2022.11 ~ 2025.03

SQL 의존성과 동시성을 운영 환경에서 풀어낸 2년

풀스택 개발자 — 회원제 특허 SaaS의 고도화·운영

100% MyBatis 환경의 **PostgreSQL** → **MSSQL** 전면 마이그레이션을 옵티마이저·라운드트립 단위로 재설계하고,
1만 건 분할 비동기 다운로드의 **이용량 우회 race condition**을 "임계구역 위치 재배치"로 풀었습니다.
여기서 체감한 한계가 그대로 부트캠프 학습으로 이어졌습니다.

동일 수준

벤더 변경 후 응답 성능 유지

원천 차단

다중 창 동시 요청 한도 우회

3→1

실무 한계 · 스터디 · 부트캠프 연결

Spring

MyBatis

MSSQL · T-SQL UDF

Stored Procedure

비동기 동시성

Apache POI

담당: 6개 검색 사이트 유지보수·개선 — 대량 문서 뷰어 · 다운로드 · 비교보기

상세 보기→

정합성 보장과 장애 격리를 설계한 B2B 물류 MSA

12개 마이크로서비스 · DDD 4계층 행사고날 · "검증=동기, 통지=비동기" 통신 분리

직전 모놀리식의 한계(한 도메인 결함이 전체 멈춤)를 계기로 **MSA + DDD**로 확장.

분산 트랜잭션 없이 **Outbox 패턴**으로 이벤트 정합성을 보장하고, **OR-Tools VRPTW**로 B2B 시간창 SLA를 제약 조건으로 모델링했습니다.

비관적 락은 스터디에서 학습한 트레이드오프를 실제 적용한 사례.

at-least-once

Outbox · 결과적 일관성

5분 → 3초

VRPTW 자동 배정 (100건 · 데모)

DB-level

비관적 락으로 race 차단

Spring Cloud 2025

Kafka · Outbox

OpenFeign

Resilience4j CB

OR-Tools VRPTW

QueryDSL

PESSIMISTIC_WRITE

담당: **company-service** 전담 + **DeliveryManager** 도메인

▶ 라이브 데모

da2joburureung

상세 보기→

LLM을 정량 평가하고, 안전하게 운영하는 백엔드

모의투자 MSA + RAG 챗봇 + LLM 기반 AIOps 설계/구현

대다수 RAG가 답변 품질을 "느낌"으로 판단할 때, **LLM-as-a-Judge + Pairwise + Self-preference bias** 차단으로 모델 교체를 데 이터로 결정했습니다. Prometheus·Loki·Claude를 묶어 알림에 원인 분석과 복구 액션을 자동 부착한 AIOps는 AI를 운영 시스템의 일 부로 통합한 사례입니다.

2.38 → 4.04

faithfulness 향상 · 모델 교체

64.3% → 8.3%

환각률 감소

< 1분

MTTD · 7종 alert 룰 차등

74% ↓

캐시 히트 응답 단축 · LLM 호출 스킵

Spring AI 1.0

pgvector

LLM-as-a-Judge

Pairwise

Prometheus · Loki · Alertmanager

HITL · HMAC-SHA256

Kafka · Redis

담당: **assistant + notification + monitoring** 전담 설계/구현

▶ 라이브 데모

ants-camp

상세 보기→

AI에게 일임하지 않고 통제한다 — 하네스 엔지니어링

harness engineering · 규칙 주입 · 가드레일 · 컨텍스트 설계

개발 사이클 단계마다 도구를 나눠 쓰되 설계·결정과 마지막 판단은 항상 사람이 합니다.

코딩 규칙·아키텍처 패턴을 SSOT 문서(CLAUDE.md·컨벤션)로 못박아 AI가 규칙을 벗어나지 못하게 하고, 작업이 끝나면 /revref./apitest가 자동으로 검토·검증해 AI의 실수를 걸러냅니다. AI에게 개발을 맡기는 게 아니라, AI를 관리·감독하는 워크플로우를 직접 엔지니어링합니다.

단계별 분리

분석 · 구현 · 리뷰 도구 분리

자동 검토

/revref · CodeRabbit 컨벤션 점검

규칙 흡수

반복 지적 → 규칙 문서 → 재발 차단

CLaude Code

서브에이전트

CLAUDE.md · 컨벤션

/revref

/apitest

CodeRabbit

원칙: AI에게 개발을 일임하지 않는다 — 통제하고 감독한다

상세 보기 →

기술 스택

	 실무 경험 (2년)	 학습 · 프로젝트
LANGUAGE	Java 8 · JavaScript	Java 17 · TypeScript
BACKEND FW	Spring 4.x (Legacy)	Spring Boot 3.5 · Spring Cloud (Gateway · Eureka · Config · OpenFeign) · Spring AI 1.0 · Spring Security
FRONTEND	JSP · AngularJS · jQuery	React · TypeScript · Tailwind CSS
DATA ACCESS	MyBatis · Stored Procedure (T-SQL)	Spring Data JPA · QueryDSL
DATABASE	MSSQL · MySQL · PostgreSQL	PostgreSQL (+ PostGIS · pgvector) · Redis
ARCHITECTURE	모놀리식 (대규모 운영)	MSA · DDD · Hexagonal · Event-Driven
MESSAGING / RESILIENCE	—	Apache Kafka · Outbox Pattern · Resilience4j (Circuit Breaker · Retry)
OBSERVABILITY	운영 로그 분석 · CS 패턴 추적	Prometheus · Grafana · Loki · Promtail · Alertmanager · Zipkin
AI / LLM	—	Spring AI · RAG · pgvector · LLM-as-a-Judge (Eval · Pairwise) · LLM 기반 AIOps · Human-in-the-Loop
OPTIMIZATION / PARSING	Apache POI (대용량 문서 파싱 · DRM 시그널 식별)	Google OR-Tools (VRPTW)
TEST	JUnit · Mockito (팀 도입 주도)	JUnit · Mockito
REFACTORING / CODE QUALITY	SonarQube (월간 코드리뷰·리팩토링 운영)	—
DEVOPS	—	Docker · Docker Compose · GitHub Actions
CLOUD / DEPLOY	—	GCP (Compute Engine · Cloud SQL · Container Registry) · AWS

이슈를 끝까지 추적하는 운영 오너십

회원제 특허 SaaS의 6개 검색 사이트 유지보수·개선 담당으로, 대량 문서 뷰어·엑셀 다운로드·비교보기를 메인으로 담당했습니다. 운영하면서 마주친 코드·기획·데이터의 불일치를 그냥 넘어가지 않고 원인까지 추적해 해결하는 방식으로 일했습니다. 담당 기능에 머무르지 않고 서비스의 상태 자체를 책임진다는 태도로 운영을 대했습니다.

"이슈를 발견하면 넘어가지 않고, 보고하고, 해결까지 책임졌다."

대량 데이터를 다루는 회원제 SaaS — 6개 검색 사이트의 유지보수·개선. 대량 문서 뷰어·엑셀 다운로드·비교보기를 메인으로, 그 외 사용자 편의성·로그 분석·외부 API 연동·DB 마이그레이션까지 담당 영역을 좁게 한정하지 않고 서비스 전체의 상태를 능동적으로 관리했습니다.

• 풀스택 개발자 • 2022.11 ~ 2025.03



이슈를 그냥 넘기지 않는다

코드 동작이 어색하거나 데이터가 이상하면 원인을 직접 추적. 표면 증상에서 멈추지 않고 근본 원인까지 들고 가서 해결.



기획 단계부터 함께 협업한다

기획 자문·사용자 관점 의견 제시·코드 불일치 검토까지 함께 맞춤. 기획팀과 활발히 소통하며 더 나은 방향을 같이 찾음.



운영을 내 것으로 본다

CS 문의·로그·이상 패턴을 능동적으로 모니터링하며 서비스 전체의 상태를 지켜봄.

★ MAIN ROLE

6개 검색 사이트 유지보수·개선

담당 기능: 대량 문서 뷰어(이지뷰어)·엑셀 다운로드·비교보기

★ 이지뷰어 도면·텍스트 동기화 작업이 연간 사용자 만족도 조사에서 2위로 선정됨

+ ADDITIONAL

유틸리티·편의성 개선

형광펜·DRM 필터링·메인·서브 뷰어 연동·다운로드 한도 모니터링

+ ADDITIONAL

분석·연동·마이그레이션

로그 기반 사용자 행동 분석·외부 번역 API 연동·PostgreSQL → MSSQL 마이그레이션



코드 수정 루틴 — 유지보수 환경에서 익힌 작업 원칙

STAGE 01

변경 전 — 코드만 보지 않는다

- ✓ **SVN history**로 과거 결정 맥락 추적 — 이 코드가 왜 이렇게 짜였는지부터 확인
- ✓ 기획서·과거 CS 이슈 확인 — 같은 문제 두 번 풀지 않기
- ✓ DB 직접 조회로 코드가 가정한 데이터와 실제 데이터의 간극 확인

STAGE 02

변경 중 — 추측 대신 재현

- ✓ 버그 재현 시나리오부터 확정 — "이 조건에서 100% 재현"을 만든 뒤 작업 시작
- ✓ 디버거 step-by-step으로 흐름 검증 — 코드 읽고 추론하지 않음

STAGE 03

변경 후 — 내 일이 끝나는 시점을 늦춘다

- ✓ 운영 로그 직접 확인 — 변경 직후 며칠간 이상 패턴 추적
- ✓ 관련 CS 인입 의식적으로 추적 — 배포 후 며칠간을 작업의 마무리 구간으로 둬

일관된 원칙: "맥락을 추적한다 + 추측 대신 재현으로 확인한다 + 내 일이 끝나는 시점을 며칠 뒤로 미룬다." 이 셋이 재직 기간 동안 큰 운영 사고 없이 작업을 유지한 실질적 근거.

02 · HOW I WORK

이슈를 발견·추적·해결한 방식

담당 기능의 경계를 좁게 두지 않았습니다. 운영 중 이상한 점 → 보고 → 원인 추적 → 해결을 능동적으로 반복했고, 특히 기획과 코드의 불일치를 발견하면 기획팀과 직접 의논해 정당한 경험이 많습니다.

👉 CASE #1

기획 단계부터 함께한 협업 — 자문·사용자 관점·코드 불일치 검토

기획과 사용자 사이를 잇는 역할로 일하기

기획 자문	기획 초기 단계에서 시스템적으로 가능한 범위·비용·우회 방법에 대한 자문을 요청받음. 받은 기획을 그대로 구현하기보다, 이 방향이 운영에 어떤 부담을 줄지를 함께 검토.
사용자 관점	실제 사용자가 되어 서비스를 써보며 불편한 지점을 직접 체감. 기획에 적힌 흐름과 실제 사용 경험 사이의 간극을 발견하면 의견을 정리해서 공유. "사용자 입장에서 편리한가"를 기준으로 기획팀과 활발히 소통.
코드 불일치 검토	새 기획안이 나오면 받자마자 "이 구조가 지금 코드와 맞나?"를 먼저 확인. 기획팀이 알고 있는 시스템 모습과 실제 운영 중인 코드의 동작이 다른 경우를 정리해서 공유 — 어느 쪽을 정정할지 의논해서 결정.
결과	"막상 만들고 보니 의도와 다르다"는 재작업 비용을 사전에 줄이고, 기획팀도 시스템의 실제 모습을 더 정확히 알게 됨. 기획·사용자·코드 사이를 잇는 역할도 함께 맡았습니다.

반복 CS 문의의 원인 분석 → 팀 논의 → 사전 차단 구현

문제의 단서를 제공하고, 결정된 방향을 책임지고 완수한 사례

상황	"문서 업로드 시 오류가 발생한다"는 사용자 문의가 반복 접수. 1차 대응은 CS팀이 "E-DRM 해제 후 재업로드"를 수동 안내하는 방식이었음.
팀 결정·할당	"수동 안내 대신 시스템 레벨에서 사전 차단하자"는 방향이 팀에서 결정됨. 해당 작업이 본인에게 할당됨.
원인 분석	반복되는 Exception 로그를 분석해, 사내 E-DRM 암호화 문서를 업로드할 때 Java 기반 문서 파서들이 던지는 특정 Exception 패턴이 존재함을 식별. E-DRM 암호화로 문서의 바이너리 구조 자체가 변형되어 파서가 정상 문서로 인식하지 못하기 때문 이라, 무작위 에러가 아니라 일정한 원인이 있는 케이스임을 확인.
구현·결과	업로드 단계에서 외부 분석 API에 넘기기 전에 사전 파싱으로 시그널을 감지해 "암호화 해제 후 재업로드" 안내 메시지를 노출. 파일 형식별로 도구를 분리해 MS Office 계열은 Apache POI, HWP는 hwplib 으로 동일 패턴 적용. 일반 파싱 오류와 E-DRM 케이스를 명확히 분리 → 불명확한 Exception 화면이 명확한 안내로 바뀌고, 동일 원인의 CS 문의 재발 없음 .

운영 기여 한눈에 보기

메인 업무(이지뷰어·엑셀 다운로드·비교보기)부터 마이그레이션·동시성·UX·다국어 출시·팀 문화까지, 운영 환경의 다양한 문제를 직접 해결한 작업들의 카탈로그. ★ **DEEP DIVE** 배지가 있는 항목은 본문에서 자세히 다룸.

이지뷰어 ↔ 도면 팝업 실시간 동기화

★ DEEP DIVE

사용자 만족도 ★ 2위

이지뷰어 문헌 이동 시 별도 팝업 도면을 자동 동기화. **URL 재호출 → 부분 렌더링(동기) → 비동기 + 콜백 재구성**의 3단계로 깜빡임·포커스 강탈·동기 멈춤을 차례로 제거. **연간 사용자 만족도 조사 2위**.

→ 07 · DEEP DIVE — VIEWER UX

PG → MSSQL 슬로우 쿼리 개선

★ DEEP DIVE

MyBatis · T-SQL

MSSQL 2016에 `string_agg(DISTINCT)` 가 없어 STUFF + FOR XML PATH 우회 → 성능 저하. 서버쿼리·JOIN·WHERE 구조 조정 후 임시 테이블 단계 분할로 해결, 기존 환경 대비 동일 응답 성능 유지.

→ 04 · DEEP DIVE — DB MIGRATION

무료 다운로드 한도 우회 차단

동시성

★ DEEP DIVE

1만 건 분할 비동기 처리에서 다중 창 동시 요청으로 한도 우회 가능했던 race condition을 **사전 차감**으로 해결. 락 기반 대안과 트레이드오프 비교 후 환경에 맞는 도구 선택.

→ 05 · DEEP DIVE — CONCURRENCY

대규모 특허 번역 — fan-out 설계 의사결정

★ DEEP DIVE

UX 성능

200건 번역 노출 시 서버 일괄 vs 클라이언트 **fan-out**의 트레이드오프(인프라 부하↑ vs 체감 응답성↑)를 정리. 인프라 수용량·페이지 UX 중요도를 근거로 fan-out 채택. 로딩 저하 우려에도 눈에 띄는 이슈 없이 출시.

→ 06 · DEEP DIVE — STREAMING UX

E-DRM 암호화 문서 사전 차단

★ DEEP DIVE

Apache POI · hwplib

반복 CS 문의의 원인 추적 → *E-DRM 암호화로 바이너리 구조가 변형되어 Java 파서가 일관된 Exception을 던지는 패턴*을 식별. 외부 API 호출 전 **Apache POI(MS Office) · hwplib(HWP)**로 사전 파싱 검증해 명확한 안내로 분기. 동일 사유 CS 재발 없음.

→ 02 · HOW I WORK · CASE #2

EU 지역 서비스 신규 출시

다국가

검증된 타 국가 서비스의 구조·패턴을 분석해, **EU 특화 요구(언어·지역 정책)**를 반영하면서도 일관성 있는 구조로 안정적 출시. 기존 시스템의 추상화 레벨을 유지하며 확장한 사례.

JUnit/Mockito 테스트 도입 주도

팀 문화

인증이 필요한 컨트롤러 테스트 방법론을 정립해 팀 대상 발표 → 팀 표준 가이드라인 마련. 테스트 방법론 아니라 그 근거까지 함께 공유.

비교 뷰어 스크롤 동기화

UX 알고리즘

기존 절대 이동거리 동기화는 길이가 다른 두 문서에서 어긋남 → 이동거리 비율(0~1) 동기화로 변경해 양쪽 문서가 항상 같은 상대 위치를 보여줌. "UX 문제를 코드 구조로 푼" 사례.

형광펜 대규모 고도화

UX 데이터 모델

드래깅·리사이징 레이어 도입, 색상 16 → 40+개 확장, 저장 포맷 **XML** → **JSON** 전환. 데이터 모델 자체를 재설계해 향후 기능 확장을 쉽게 만든 작업.

로그 기반 사용자 행동 패턴 조사

운영 지원

CS·영업팀 요청을 받아 로그인 시간이 불규칙한 사용자 등 의심 패턴 대상자를 **로그 다각 분석**으로 조사해 운영팀에 보고. 이상 로그인 등 의심 패턴을 읽어내는 관점으로 접근.

DEEP DIVE - DB MIGRATION

PostgreSQL → MSSQL 마이그레이션 후 슬로우 쿼리 개선

시행착오로 해결한 작업을 이후 학습으로 원리 레벨에서 설명할 수 있게 된 사례

P · 팀 차원에서 PG → MSSQL(구버전, 2016) 전체 이관을 진행. 마이그레이션 후 특정 쿼리가 눈에 띄게 느려진 케이스를 담당해 개선. 특히 주된 원인은, 중복 제거 문자열 집계에서 PG의 `string_agg(DISTINCT)` 가 MSSQL 2016에는 없어 **STUFF + FOR XML PATH + DISTINCT** 서브 쿼리로 우회해야 했고, 이 우회 자체가 큰 성능 저하를 유발.

A · 같은 결과를 내는 여러 SQL 형태를 시도하며 단계적으로 접근:

① 호출 경로 식별 — 영향 범위 먼저 파악

슬로우 쿼리가 발생하는 화면·기능을 먼저 식별해 회귀 검증 범위를 가늠.

이유: 쿼리만 보고 고치면 같은 쿼리가 호출되는 다른 화면에서 회귀가 날 수 있음.

② 서브쿼리 ↔ JOIN ↔ UNION 변환 시도

서브쿼리로 짰 부분을 JOIN으로, JOIN을 UNION으로 바꿔보며 MSSQL에서 어떤 형태가 빠른지 실행 시간 측정으로 비교.

결과: 일부 쿼리는 개선, 일부는 미미.

③ WHERE절 구조 조정

조건 순서·표현 방식을 다양하게 시도.

결과: 미미한 개선. 근본 해결은 안 됨.

④ 임시 테이블로 단계 분할 — 결정적 해결

복잡한 한 방 쿼리를 단계별로 쪼개서 임시 테이블에 넣고 다음 단계에서 사용.

결과: 큰 개선 확인. 이게 결정적이었음.

R · 벤더가 바뀌어도 기존 환경 대비 동일 수준의 응답 성능 유지하며 슬로우 쿼리 개선 완료.

 당시 한계와 이후 학습

당시엔 옵티마이저 개념을 깊이 알지 못한 채 시행착오로 해결. 이후 학습 결과로 이해한 메커니즘: MSSQL 옵티마이저는 참여 테이블 수와 데이터 분포가 복잡해질수록 통계 추정치 빗나가 잘못된 조인 순서나 비효율적 조인 방식(예: 해시 조인이 적절한데 중첩 루프를 택함)을 선택하는 경향이 있음. 거대한 단일 쿼리를 통째로 던지면 옵티마이저가 길을 잃는 상황이었던 것. 임시 테이블 분할은 각 단계마다 데이터 크기·통계가 명확한 상태에서 옵티마이저가 판단하도록 강제하는 효과. 다음 작업 시 접근법: 실행 계획을 먼저 확인하고 옵티마이저의 추정·실제 차이를 진단한 뒤 접근.

→ 학습 연결 고리

이 경험에서 **SQL 의존성·벤더 종속성의 한계**를 체감 → **ORM(JPA)** 학습으로 직결 → 영속성 컨텍스트·벤더 독립 데이터 접근 계층 설계를 학습 → 부트캠프 프로젝트의 **JPA + QueryDSL** 설계에 적용.

DEEP DIVE - CONCURRENCY

임계구역을 긴 로직 뒤에서 맨 앞으로 옮긴 비동기 동시성 설계

1만 건 분할 비동기 처리에서 다중 창 동시 요청을 통한 한도 우회 원천 차단 + 비동기 모니터링 누락 제거

P · 1만 건 규모 다운로드를 100건씩 분할 비동기 처리하는 회원제 기능에서, 이용량을 모든 처리 완료 후 집계하는 구조 → 사용자가 여러 창에서 동시에 다운로드하면 검사 시점에 한도가 비어있어 제한 우회(race condition). 비동기 특성상 실패 다운로드의 모니터링 알림도 누락.

A · 임계구역의 위치 자체를 재설계 — 옵션별로 트레이드오프 비교:

대안 검토 — 동시성 보호 옵션 비교

REJECTED · DB 락

SELECT ... FOR UPDATE

비동기 처리 시간(수 초~수십 초) 동안 락 점유
→ 처리량 저하 + 다른 정상 요청까지 블로킹.

REJECTED · 분산 락

Redis · ZooKeeper


단일 DB 환경에 오버엔지니어링. 외부 의존성 추가 + 운영 복잡도 상승. 본 문제는 DB 한 곳에서 풀 수 있음.

CHOSEN · 임계구역 재배치

사전 차감 (Front-loading)

이용량 집계를 **critical section** 가장 앞으로 이동하고 사전 차감 방식 전환. 락 없이도 race 차단 + 실패 시 롤백 가능.

✗ BEFORE — 사후 집계 (race 발생)



✓ AFTER — 사전 차감 (race 차단)



요점: 긴 시간 소요 로직 **이전에** 임계구역을 두면 락 없이도 race를 막을 수 있다.

비동기 모니터링은 호출자 예외 컨텍스트 밖에서 발생하므로 완료 분기에서 **명시적 메트릭 로깅**이 필수.

R · 동시 다발 요청을 통한 이용량 제한 우회를 구조적으로 차단, 비동기 환경 모니터링 누락 제거.

📖 당시 한계와 이후 학습

당시엔 "여러 방법 중 사전 차감이 맞다"는 판단으로 해결했으나, 락 기반 대안을 체계적으로 비교하지 못한 상태였음. 이후 학습 결과로 정리한 대안: 비관적 락(PESSIMISTIC_WRITE)으로 차감 row를 잠그거나, 낙관적 락(@Version)으로 충돌 시 재시도하는 방식. 해당 환경에서의 판단 근거: 다운로드 처리 시간이 길어 락 대기 비용이 크므로 사전 차감이 적합. 현재는 환경에 따라 도구를 선택할 수 있는 단계에 도달.

→ 학습 연결 고리

"긴 로직 이전에 임계구역을 둔다"는 동시성 설계 원칙을 체득 → 부트캠프에서 분산 락·동시성 제어를 자칭 발표(낙관·비관·분산 락 트레이드오프) → 다 2조부 프로젝트의 seq 채번 race condition에서 의식적으로 비관적 락(PESSIMISTIC_WRITE) 선택. 3단계 학습 곡선의 시작점.

DEEP DIVE — STREAMING UX

대규모 특허 번역 — 서버 일괄 vs 클라이언트 fan-out, 트레이드오프 기반 선택

두 방식의 비용·체감 응답성 트레이드오프를 정리해 의사결정. 인프라 부하 증가를 감수하고 UX를 택한 근거가 분명한 사례

P · 특허 검색 결과 한 화면에 최대 **200건**의 항목이 노출되며, 각 항목의 제목·요약을 사용자의 언어로 번역해 함께 표시해야 함. 번역 API는 건당 수백 ms 단위라 누적 시간이 큼. 팀 내에서 "번역 도입 후 로딩 속도 저하"에 대한 우려가 있었음.

A · 두 가지 방식의 트레이드오프를 비교 후, 인프라 수용량과 UX 중요도를 근거로 방식 B 선택. 프론트와 협업해 응답 처리 흐름 설계.

① 방식 A vs B 트레이드오프 정리

A: 서버가 200건 번역 후 한 번에 응답 — 통신은 1회로 효율적이나 사용자는 전부 번역될 때까지 빈 화면 대기. **B**: 원문 즉시 응답 + 클라이언트가 항목별로 번역 fan-out — 서버 통신 1회 → 최대 200회로 증가(**인프라 부하↑**), 대신 첫 화면 대기 시간(TTFB) 극적 단축.

판단 기준: 어느 쪽이 빠르거나, 어느 쪽 비용을 감당할 수 있고 어느 쪽 가치가 더 중요한가를 두 축으로 결정.

② B 선택 근거 — 인프라 수용량 + UX 중요도

우리 인프라가 200회 동시 요청 수준을 감당 가능하다는 정보가 있었고, 해당 페이지는 사용자 경험이 중요한 페이지로 분류되어 있었음 → **비용은 감당 가능, 가치는 우위**라는 결론으로 B 채택.

③ 구현 — 원문 즉시 렌더 + 비동기 도착 순 교체

서버는 번역되지 않은 원본을 먼저 빠르게 응답해 화면을 즉시 그림. 이후 클라이언트가 각 항목별로 번역 API를 비동기 호출하고, 응답이 도착하는 순서대로 해당 영역만 원본→번역문으로 교체.

사용자 경험: 빈 화면 0초 → 원본 즉시 노출 → 번역 도착 항목부터 자연스럽게 갱신.

R · 팀 내에서 우려가 있던 "번역 도입 후 로딩 속도 저하"가 눈에 띄는 이슈 없이 출시. 인프라 부하 증가라는 비용을 사전에 인지·감수한 결정이라 출시 후에도 예상 범위 내에서 동작.

당시 한계와 이후 학습

당시엔 트레이드오프를 직접 비교해 적용했으나, 이것이 일반화된 패턴임은 인식하지 못한 상태였음. 이후 학습 결과로 이해한 패턴: **Client fan-out · Progressive Rendering** — TTFB(첫 반응 시간) 단축이 체감 응답성을 결정한다는 원칙이며, HTTP 스트리밍·SSE·GraphQL @defer 등 표준이 같은 철학에서 출발. 다음 작업 시 접근법: SSE 같은 표준 프로토콜이나 viewport 우선순위 큐를 함께 검토해 인프라 부하도 같이 줄이는 방향 가능.

★ DEEP DIVE - VIEWER UX

이지뷰어 ↔ 도면 팝업 실시간 동기화 — 연간 사용자 만족도 ★ 2위

메인 담당 기능의 핵심 사용성 작업. 단계별로 문제 원인을 짚어 개선한 결과, 그 해 전체 개선 기능 중 사용자 만족도 2위로 선정

P·메인 창에는 다수의 특허 문헌을 빠르게 탐색할 수 있는 "이지뷰어"가 있고, "도면 보기"를 클릭하면 별도 컨트롤러 URL을 호출해 전체 HTML을 받아오는 팝업 창이 열리는 구조. A문헌 도면을 본 상태에서 이지뷰어로 다른 문헌을 탐색해도 팝업은 A문헌 도면 상태로 고정되어, 사용자가 매번 "도면 보기"를 다시 클릭해야 하는 불편이 있었음.

A·이지뷰어 문헌 이동 시 팝업 도면이 자동 동기화되도록 개선. 각 단계에서 드러난 문제 원인을 정확히 짚어 다음 단계로 이어감.

1차 — 팝업 자동 갱신 (URL 재호출)

B문헌으로 이동 시 도면 조회 컨트롤러 URL을 다시 호출해 팝업 창 전체를 새로 불러오는 방식.

남은 문제 3가지: ① 페이지 전체 재로딩으로 느낌 ② 화면이 순간 하얗게 깜빡임 ③ 새 URL 로드 시 브라우저 보안 정책에 의해 포커스가 팝업 창으로 강제 이동 → 이지뷰어에서 빠르게 문헌을 넘기던 탐색 흐름이 매번 끊김.

2차 — 부분 렌더링 (동기 AJAX)

깜빡임·포커스 강탈의 근본 원인이 "팝업 URL을 바꿔 페이지 전체를 재로딩"하는 데 있다고 판단. 팝업 HTML을 고정 영역(헤더·툴바) + 가변 영역(도면)으로 분할하고, 팝업 URL은 그대로 둔 채 가변 영역의 HTML 조각만 동기 AJAX로 받아 innerHTML로 교체.

해결: 깜빡임·포커스 강탈 사라지고 전송량 감소로 속도 개선. 남은 문제: 동기 AJAX 특성상 응답 도착 전까지 메인 스레드가 멈춰 "순간 멈춤"이 인지됨.

3차 — 비동기 호출 + 콜백 기반 실행 순서 재구성

AJAX를 비동기로 변경. 단순히 동기→비동기 전환만으로는 부족하고, 응답 시점에 의존하는 후속 로직(도면 초기화 JS 등)이 응답 완료 후 실행 되도록 콜백 기반으로 코드 구조를 재정비.

해결: 응답 대기 중에도 사용자 입력에 반응 가능해져 멈춤 현상까지 해소. 1·2차에서 드러난 모든 문제(깜빡임·포커스 강탈·속도·멈춤)가 최종적으로 모두 개선됨.

R·연간 사용자 만족도 조사에서 그 해 개선 기능 중 2위로 선정. 기능이 동작하는 데 멈추지 않고 사용자 흐름을 끊지 않는 것까지 가져간 점이 실질적 평가 근거.

회고

AJAX 적용 자체보다, 각 단계의 문제 원인을 정확히 짚어 다음 단계로 이어간 점이 중요했음. 페이지 전체 재로딩 → 부분 교체 → 비동기화로의 흐름은 결과적으로 "브라우저가 강제하는 동작을 피하기 위해 점점 더 가벼운 단위로 갱신 범위를 좁혀 나간 과정"이었음.

→ 작업의 의미

브라우저가 강제하는 동작 단위를 좁혀 사용자 흐름을 보존하는 설계. 사용자 경험을 코드 구조 레벨에서 직접 풀어낸 작업.

점진적 응답성 개선(전체 재로딩 → 부분 렌더링 → 비동기 갱신)의 사고 패턴은 이후 대규모 특허 번역(서버 일괄 응답 → 클라이언트 fan-out + 점진 교체)으로 이어지고, 부트캠프 프로젝트의 ants-camp 클라이언트 fan-out 구조까지 일관되게 적용됨.

경력 중 사용 스택

영역	스택
Language / Framework	Java 8 · Spring 4.x (Legacy) · JavaScript
Data Access	MyBatis · Stored Procedure (T-SQL)
Database	PostgreSQL → MSSQL 마이그레이션
Document Parsing	Apache POI (MS Office) · hwplib (HWP) — E-DRM 시그널 식별
Test	JUnit · Mockito
Frontend (Legacy)	JSP · AngularJS · jQuery 계열 — 비동기 렌더링·형광펜 레이어·스크롤·이미지 동기화

위는 레거시 코드베이스 운영 환경의 스택. 부트캠프 프로젝트(Java 17 · Spring Boot 3.5 · React/TS 등)에서 모던 스택으로 학습·적용 병행 → 다음 섹션(GROWTH MAP) 참조.

실무 한계 → 학습 동기 → 부트캠프 적용

실무에서 시행착오로 풀어낸 문제들이 그대로 "왜 그게 효과 있었는지 알고 싶다"는 공부로 이어졌습니다. 이론으로 채운 뒤 다시 프로젝트에서 검증하는 사이클이 두 번 완결.

 GROWTH CYCLE #1 - SQL · 벤더 종속성 · DB 깊이

PG → MSSQL 슬로우 쿼리 시행착오 → ORM 학습 + 실행 계획 공부 → 부트캠프 프로젝트 적용

실무 · 100% MyBatis 환경에서 슬로우 쿼리를 경험적 시행착오로 풀었지만, "왜 효과 있는지" 설명할 수 없는 부분이 마음에 남음.

학습 · 영속성 컨텍스트·JPQL·벤더 독립 데이터 접근 계층 설계를 학습. 옵티마이저·실행 계획·카디널리티 추정 개념도 함께 정리. "왜 ORM이 필요한지"를 실무 경험으로 설명 가능.

적용 · 부트캠프 프로젝트에서 JPA + QueryDSL로 데이터 액세스 계층 직접 설계. PostGIS 같은 벤더 특수 기능은 Native Query로, 일반 도메인은 JPA로 — 이 분기 기준도 실무에서 체감한 한계로부터 나온 판단.

비동기 다운로드 **race** 직감으로 해결 → 락 트레이드오프 발표 → 다2조부 비관적 락 의식적 선택

실무 · "긴 로직 이전에 임계구역을 둔다"는 방식으로 **race**를 풀었지만, 어떤 락이 어떤 상황에 맞는지 체계적으로 모름.

학습 · 부트캠프 스터디에서 낙관적/비관적/분산 락 트레이드오프를 자청 발표. 각 락의 동작 원리·임계구역 크기·충돌 빈도에 따른 선택 기준을 코드 레벨로 검증.

적용 · 다2조부 프로젝트의 **seq** 체번 **race condition**에 비관적 락(`PESSIMISTIC_WRITE`) 적용. 분산 락도 검토 후 "단일 인스턴스 토폴로지엔 오버 엔지니어링"이라는 판단으로 배제 — 여러 옵션을 알고 의도적으로 선택한 사례.

01 · OVERVIEW

정합성 보장과 장애 격리를 설계한 B2B 물류 MSA

직전 모놀리식(monolith)에서 한 도메인에 결함이 나면 전체가 멈추고, 특정 도메인 전용 기술(PostGIS)을 전 팀원이 설치해야 했던 비효율을 직접 겪고 도메인별 독립 배포·기술 선택이 가능한 MSA로 확장. B2B 도메인을 코드에 녹이기 위해 DDD 4계층(핵사고날)을 적용하고, 서비스 간 통신은 "검증=동기(Feign), 통지=비동기(Kafka)"로 의도적으로 분리했습니다.

"분산 트랜잭션 없이 정합성을, 장애 전파 없이 통신을."

전국 17개 허브를 거점으로 한 스파르타 물류 — 업체·허브·상품·주문·배송을 MSA로 분리한 B2B 물류 시스템에서 **company-service** 전담 + **DeliveryManager** 도메인 설계. Outbox 패턴 · Circuit Breaker · OR-Tools VRPTW · 비관적 락을 비즈니스 근거에서 출발해 채택.

- 2026 · 부트캠프 5인 · 담당: company-service + delivery-service 내 3개 도메인
- Spring Cloud 2025 · Kafka · OR-Tools · Keycloak

at-least-once

이벤트 정합성 보장
Outbox 패턴 · 분산 트랜잭션 없이

5분 → 3초

배송 배정 자동화
수동 배정 → OR-Tools VRPTW (100건 기준 · 데모)

DB-level

race 원천 차단
비관적 락 · 재시도 로직 없이

02 · SERVICE OVERVIEW

스파르타 물류 — MSA 기반 국내 B2B 물류 관리 및 배송 시스템

전국 **17개 지역 허브 센터**를 거점으로 한, "공급업체 → 허브 → 허브 → 수령업체" 전 구간을 자동화한 **B2B 물류 관리 플랫폼**.

스파르타 물류는 전국 17개 도/광역시에 허브 센터를 보유한 가상의 B2B 물류 회사입니다. 각 허브는 여러 업체의 물건을 보관하며, 주문이 발생하면 시스템은 **출발 허브 → 목적지 허브** 간 화물 이동(허브 배송 담당자)과 **최종 허브 → 수령 업체 배송**(업체 배송 담당자) 두 트랙을 분리해 처리합니다.

예시 시나리오 — "부산 수산물 도매 업체가 경기도 일산의 건조 식품 가공품 50개를 주문" → 시스템이 **경기도 허브** → **부산 허브**로 화물 이동을 계획하고, 도착하면 **부산 허브 소속 업체 배송 담당자**가 최종 업체로 전달.

시스템 핵심 도메인 (8개)

01 · COMPANY ★ 담당

업체 관리 (생산·수령)

생산업체·수령업체로 구분, 모든 업체는 특정 허브에 소속, 업체 삭제 시 주문/상품/배송 등 타 서비스에 이벤트 통지 필요.

02 · HUB · HUBPATH

17개 허브·허브 간 경로

전국 도/광역시 17개 센터 관리 + 허브 간 이동 경로 매핑. 모든 화물의 시작/도착점.

03 · PRODUCT

상품·재고 관리

모든 상품은 특정 업체와 허브에 소속, 주문 발생 시 재고 감소, 취소 시 복원.

04 · ORDER

주문 라이프사이클

주문 생성 → 재고 검증·차감 → 배송 트리거, 재고 부족 시 주문 실패, 삭제 시 논리 삭제 (deleted_at).

05 · DELIVERY ★ 담당

배송·담당자·경로 (3개 도메인 통합)

배송 분체 + DeliveryManager(허브당 10명 + 전체 10명) + DeliveryRoute(경로 기록)를 한 컨텍스트로 통합. **매일 06:00 VRPTW 자동 배정**.

06 · USER · AUTH

4단계 권한 관리

마스터 / 허브 관리자 / 배송 담당자 / 업체 담당자. **Keycloak + JWT**로 권한 검증.

07 · NOTIFICATION

Slack 메시지 관리

시스템·사용자 발신 슬랙 메시지 전부 엔티티에 저장. Incoming Webhook으로 외부 발송.

08 · AI

AI 상품 정보 생성

상품 등록 시 LLM 기반 설명 자동 생성. AI 응답 로그는 별도 트랜잭션(REQUIRES_NEW)으로 분리해 본 로직 무영향.

2-Track 배송 구조 — 발제문 기반

트랙	역할	인원	배정 방식
허브 배송 담당자	허브 간 화물 이동 (경기도 허브 → 부산 허브)	전체 10명	대기시간·순번 기반 라운드로빈
업체 배송 담당자	최종 허브 → 수령 업체 배송	허브당 10명	OR-Tools VRPTW (시간창·차량 부하 균등)

두 트랙의 업무는 **명확히 분리** — 허브 배송 담당자는 허브 → 업체 배송 불가, 업체 배송 담당자는 허브 간 배송 불가. 이 도메인 특성을 코드로 강제하기 위해 **배정 알고리즘 자체를 트랙별로 분리**(라운드로빈 / VRPTW)했습니다.

03 · DESIGN GOALS

설계 도전 과제와 핵심 기여

핵심 도전 과제

- 부산 트랜잭션 없이 이벤트 유실·유령 이벤트 차단 — DB 커밋과 Kafka 발행의 원자성 불가
- 외부 서비스 장애 시 **연쇄 전파(cascading failure)** 차단 — 대기 스레드 누적 문제
- B2B의 시간창 **SLA** 준수 — 후처리 정렬 아닌 제약 조건으로 모델링 필요

핵심 기여 (개인)

- company-service 전담 + DeliveryManager 도메인 **DDD 4계층** **책사고날** 설계
- 업체 삭제 이벤트의 **Kafka + Outbox** 패턴 구현 (Saga 대안 검토 후 채택)
- user/hub/order 호출의 **OpenFeign + Resilience4j** CB 적용
- 매일 06:00 cron의 **OR-Tools VRPTW** 일괄 배송 최적화


- seq 채번의 **Read-Modify-Write race** — 동시 등록 시 중복 발급 위험

- seq 채번 **비관적 락(PESSIMISTIC_WRITE)** — 스터디에서 학습한 트레이드오프 적용

04 · ARCHITECTURE

시스템 아키텍처

12개의 마이크로서비스를 **Spring Cloud Gateway · Eureka**로 묶고, 통신은 **검증=동기(Feign)**, **통지=비동기(Kafka Outbox)**로 분리합니다. 바운디드 컨텍스트별 PostgreSQL 분리(database-per-service)로 서비스 독립성·장애 격리를 확보했습니다.



설계 의도: 12개 서비스를 7개 바운디드 컨텍스트(파션)로 묶고, 각 컨텍스트는 자기 PostgreSQL을 가짐(database-per-service). 배송 컨텍스트는 처음엔 `delivery / delivery_manager / delivery_route` 3개 서비스로 분할 시도했으나, **강한 응집성·동일 트랜잭션 경계 요구** 때문에 `delivery-service` 한 컨텍스트로 통합하고 내부 도메인으로 분리.

설계 의사결정과 근거

결정	대안	선택 이유 — 트레이드오프 명시
MSA + DDD 헥사고нал	모놀리식 (omin)	직전 omin에서 한 도메인에 결함이 나면 전체가 멈추고 도메인 전용 기술(PostGIS)을 전 팀원이 설치해야 했던 비효율 직접 경험 → 도메인별 독립 배포·기술 선택 이 가능한 MSA로.
database-per-service	공유 DB·schema 분리	바운디드 컨텍스트별 PostgreSQL 분리 → 서비스 독립성·장애 격리. 데이터 정합성은 Outbox 이벤트로 별도 보장.
"검증=동기, 통지=비동기" 통신 분리	전부 동기 / 전부 비 동기	정합성 검증("이 hub가 있나?")은 응답을 받아야 진행 가능 → 동기(Feign). 삭제 통지는 응답 불 필요 → 비동기(Kafka). 의도적 분리.
Outbox 패턴	Saga·2PC·직접 Kafka 발행	단방향 통지·응답 불필요라 full Saga는 과함. 2PC는 분산 트랜잭션 회피. 직접 발행은 유실/유령 이벤트 위험 → at-least-once + 결과적 일관성 의 Outbox가 적정.
단일 인스턴스 → 분산 락 생략	ShedLock·리더 선 출	각 서비스 단일 인스턴스 배포 토폴로지 → Outbox 스케줄러 중복 실행 자체가 발생 X. 수평 확장 시 ShedLock + 컨슈머 먹통 처리 추가 예정.

05 · KEY CONTRIBUTION ①

📦 CONTRIBUTION #1

이벤트 유실·유령 이벤트 없는 비동기 통지 — Kafka + Outbox 패턴

분산 트랜잭션 없이 **at-least-once**·**결과적 일관성** 보장. 단위 테스트로 단일 이벤트 실패가 나머지 발행을 막지 않음 검증

P·업체 삭제 시 주문·상품 등 타 서비스 통지가 필요한데, "DB 커밋 → Kafka 발행" 사이 발행 실패 시 **이벤트 영구 유실**(DB는 지워졌는데 남들은 모름), 발행 후 DB 롤백 시 **유령 이벤트**(다른 서비스는 삭제됐다고 알고 처리). 분산 트랜잭션(2PC)은 가용성을 해치고 MSA와 부적합.

A·삭제 트랜잭션 내 `OutboxEvent (PENDING) 원자 저장` → DB 커밋과 함께 커밋(또는 함께 롤백). `OutboxEventScheduler` 가 `@Scheduled(fixedDelay=10000)` 로 10초마다 PENDING을 Kafka로 발행 → `PUBLISHED`. 실패 시 PENDING 유지 → 다음 주기 자동 재발행.

R·분산 트랜잭션 없이 **at-least-once 발행 + 결과적 일관성** 보장. 단위 테스트로 단일 이벤트 실패가 나머지 발행을 막지 않음 검증.

CODE `CompanyService.java` · `deleteCompany` 원자 저장 `OutboxEventScheduler.java` · 10s 폴링 발행

`OutboxEvent.java` · 상태 모델 `OutboxEventSchedulerTest.java` · 단위 테스트

대안 검토 — 옵션별 트레이드오프

REJECTED · 2PC

분산 트랜잭션 코디네이터

모든 참여자가 잠금을 유지 → **가용성 저하**, MSA와 부적합. 코디네이터 자체가 SPOF.

REJECTED · Saga

보상 트랜잭션 체인

다중 단계 트랜잭션엔 강력하나, 본 케이스는 **단방향 통지·응답 불필요**라 full Saga는 과함. 보상 로직 작성 비용도 큼.

CHOSEN · OUTBOX

트랜잭셔널 Outbox

도메인 변경과 이벤트를 **같은 트랜잭션에 기록** → 별도 publisher가 polling으로 Kafka 발행 → 실패 시 PENDING 유지·재시도. **at-least-once.**

```
// 업체 삭제 트랜잭션 내 Outbox 원자 저장
@Transactional
public void deleteCompany(UUID companyId) {
    companyRepository.delete(companyId);
    outboxRepository.save(new OutboxEvent(
        "company.deleted", companyId, payload, "PENDING"
    )); // 같은 트랜잭션 - 원자 보장
}

// 10초마다 PENDING → Kafka
@Scheduled(fixedDelay = 10000)
public void publish() {
    outboxRepository.findByStatus("PENDING").forEach(event -> {
        kafkaTemplate.send(event).addCallback(
            ok -> outboxRepository.markPublished(event.getId()),
            fail -> log.warn("retry next tick")
        );
    });
}
```

06 · KEY CONTRIBUTION ②

CONTRIBUTION #2

검증=동기, 통지=비동기 — Feign + Circuit Breaker로 통신 의도 분리

외부 서비스 장애의 연쇄 전파 차단 — CB(window 10·실패율 50%·OPEN 10s·slow-call 3s) + Retry 3회로 fallback 즉시 반환

P· 외부 서비스 호출이 타임아웃까지 블로킹되면 대기 스레드 누적 → 내 서비스까지 연쇄로 죽음(cascading failure). 단순 동기 호출은 한 서비스 장애가 전체로 번지는 구조.

A· 통신 의도를 의도적으로 분리: "정합성 검증=동기(Feign)", "삭제 통지=비동기(Kafka)". user/hub/order 호출은 @CircuitBreaker + @Retry 로 감쌌. CB(window 10·실패율 50%·OPEN 10s·slow-call 3s·retry 3회/500ms)로 fallback 즉시 반환.

R· CB OPEN 시 즉시 fallback 반환 → 대기 스레드 누적·연쇄 장애 차단. CB 상태전이(OPEN/CLOSED/HALF_OPEN)·호출차단·slow-call 전체 로깅.

CODE [HubClientImpl.java](#) · CB+fallback [ResilienceConfig.java](#) · 상태전이 로깅

[application-docker.yml](#) · CB 설정값

연쇄 전파가 어떻게 번지나 (Why → Why)

실제 장애 시나리오 — hub-service 일시 장애

- 외부 호출이 타임아웃까지 스레드를 점유
- 풀에서 스레드가 빠르게 소진 → 새 요청이 대기 큐에 적체
- 대기 요청도 결국 타임아웃 → company-service 자체 응답 지연
- fail-fast가 없으면 장애가 양방향으로 전파 → CB OPEN 시 즉시 fallback해 점유 시간을 타임아웃에서 수 ms로 끌어냄


```
@Retry(name = "hubService")
@CircuitBreaker(name = "hubService", fallbackMethod = "hubServiceFallback")
public boolean validateHubExists(UUID hubId) {
    return hubClient.exists(hubId); // 동기 검증
}

private boolean hubServiceFallback(UUID hubId, Throwable t) {
    log.warn("Hub validation fallback - CB OPEN. hubId={}", hubId);
    return false; // 즉시 반환 → 스레드 점유 X
}
```

설정 항목	값	이 값으로 정한 이유
sliding window	10 calls	실패율 산출 표본 크기. 너무 작으면 1~2건 실패에 과민 반응, 너무 크면 장애 감지가 늦음 → 둘의 절충점
failure rate threshold	50%	retry 3회를 통과하고도 절반이 깨지면 일시적 결함이 아니라 명백한 장애로 판단. 그 이하(예: 30%)면 단발성 오류에도 차단돼 과민
wait in OPEN	10s	외부 서비스 재기동·순간 부하 해소에 통상 수~십수 초. 더 짧으면 복구 전 재요청이 몰려 재차 OPEN, 더 길면 정상화 후에도 차단 지속
half-open calls	3	1건 성공은 우연일 수 있어 성급한 CLOSE를 방지. 3건 시험 호출로 실제 복구 여부를 확인 후 닫음
slow call threshold	3s	등록 플로우가 허용할 수 있는 지연 상한. Feign read timeout보다 짧게 뒤 '느린 성공'도 장애로 간주해 미리 차단
retry	3회 / 500ms	패킷 손실·순간 GC 같은 일시 결함은 보통 1~2회 재시도로 흡수. 500ms 간격으로 순간 부하 분산, 3회 초과 시 일시 결함이 아니라 보고 CB에 위임

값 선정 전제 — 데모 트래픽 기준의 보수적 baseline. Resilience4j 기본값을 출발점으로 위 근거에 따라 조정했고, 운영 전환 시 실제 호출량·지연 분포로 부하 테스트 후 재 튜닝하는 것을 전제로 한 초기값.

CONTRIBUTION #3

시간창을 제약으로 모델링한 일괄 배송 최적화 — OR-Tools VRPTW

B2B SLA의 관건인 시간창 준수를 사후 정렬이 아니라 솔버의 직접 제약으로 모델링. 수동 5분 → 자동 3초 (100건 기준 · 데모)

P · B2B 물류는 업체 영업시간(예: "오전 9~11시 입고")이 **SLA의 핵심**. 어기면 계약 위반 → **시간창을 제약(constraint — 솔버가 반드시 지켜야 하는 조건)으로 모델링**해야지, 후처리 정렬로는 보장 불가. 단순 라운드로빈(들어온 순서대로 담당자에게 균등 배분)은 거리·시간창·차량 부하 균등을 못 고려해 비효율.

A · 매일 06:00 스케줄러가 허브별 당일 배송을 모아 **VRPTW로 일괄 최적화**. 트랙 분리 — 허브 간 = 라운드로빈, 업체 = **OR-Tools VRPTW**. 제약을 모두 만족하는 해가 없으면(infeasible) 시간창을 단계적으로 완화해 재시도.

입력 — Haversine 공식(위·경도 좌표로 두 지점 간 직선거리 계산)으로 시간·거리 행렬 생성

제약 — 시간창 ± 30 분 · 라우트 최대 480분(8시간) · 차량당 상한 `ceil(총건/담당자수)` 로 부하 균등

솔버 — 가까운 지점부터 이어 붙여 초기 경로를 빠르게 만드는 휴리스틱(`PATH_CHEAPEST_ARC`) + 그 경로를 반복 개선하며 부분 최적에 갇히지 않도록 탐색하는 기법(`GUIDED_LOCAL_SEARCH`), 탐색 5초 제한

가용성 — 해가 없을 때(infeasible) 시간창 단계적 완화 + 스케줄러 레벨 3회 재시도(10초 간격)

R · 시간창을 솔버의 직접 제약으로 모델링해 **SLA 보장 가능한 자동 배정 체계** 확보. 해가 없을 때도 시간창 완화로 가용성 확보.

CODE `OrToolsRouteOptimizationService.java` · 솔버 구성 `CompanyDeliveryAssignmentService.java` · 시간창 완화

`CompanyDeliveryAssignmentScheduler.java` · 06:00 cron+재시도

`HubDeliveryAssignmentService.java` · 라운드로빈

대안 검토 — 왜 OR-Tools인가

REJECTED · K-means

거리 기반 군집화

시간창·차량용량을 **제약으로 못 넣음**. 클러스터링 후 시간창 검증은 사후 필터링 → 위반 건은 다음 날로 밀려 **SLA 위반**. 초기값에 의존하는 휴리스틱(경험적 어림법)이라 결과도 불안정.

REJECTED · pgRouting

경로 탐색 (A→B 최단)

경로 탐색엔 강하지만 "어떤 묶음을 누구에게 **배정**"하는 **할당(assignment)** 문제는 안 풀. 지리 공간 시각화·근사 계산용에 가깝고, 제약 만족 문제(CSP — 여러 제약을 동시에 만족하는 해를 찾는 문제)에는 부적합.

CHOSEN · OR-TOOLS

제약 만족 솔버 (CSP)

시간창·차량 용량·작업 시간을 **솔버가 직접 지키는 제약으로 선언** → 솔버가 제약 안에서 최적해 탐색. 해가 없으면 시간창 완화 단계적 재시도 가능.

OR-Tools VRPTW 구성요소 한눈에

개념	코드 표현	의미
Depot	<code>depot</code> 인덱스	모든 라우트의 출발·복귀 지점(허브)
Dimension	<code>AddDimension(...)</code>	라우트 따라 누적되는 값(시간·거리·용량)에 제약 부여
Time Window	Dimension slack + 노드별 <code>setRange</code>	업체별 영업시간 — 도착 가능 구간
1st Solution Strategy	<code>PATH_CHEAPEST_ARC</code>	초기해를 빠르게 만드는 휴리스틱 (가까운 노드 우선)
Local Search Metaheuristic	<code>GUIDED_LOCAL_SEARCH</code>	초기해를 점진적으로 개선 — 국소최적 탈출 메커니즘

개념	코드 표현	의미
Time Limit	setTimeLimit	솔버 탐색 시간 상한 — 충분히 좋은 해에서 stop

```
// VRPTW 핵심 구성
// nodes: 방문 지점 수(허브+업체) / vehicles: 담당자 수 / depot: 출발·복귀 지점(허브) 인덱스
RoutingIndexManager manager = new RoutingIndexManager(
    nodes, vehicles, depot
);

// AddDimension: 시간/거리/용량처럼 라우트 따라 누적되는 값에 제약 부여
routing.AddDimension(
    timeCallback,
    30,          // 노드별 대기 가능 여유(slack) - 시간창 도착에 30분 버퍼
    480,         // 한 담당자 라우트 총 시간 상한(분) = 8시간
    false, "Time" // depot 시작 시점에 누적값 리셋 안 함
);


// 차량당 상한 - 부하 균등
int maxPerVehicle = (int) Math.ceil((double) total / vehicles);

// 솔버 구성 = "초기해를 빠르게 + 그 해를 개선" 2단
RoutingSearchParameters params = main.defaultRoutingSearchParameters()
    .toBuilder()
    .setFirstSolutionStrategy(FirstSolutionStrategy.PATH_CHEAPEST_ARC) // 가까운 노드부터 그리디로 초기해
    .setLocalSearchMetaheuristic(LocalSearchMetaheuristic.GUIDED_LOCAL_SEARCH) // 초기해를 개선하며 국소최적 탈출
    .setTimeLimit(Duration.ofSeconds(5))
    .build();
```

왜 일괄(batch)인가 — 실시간 배정 = 들어오는 순서대로 그리디 → **국소 최적**(지금 가까운 사람에게 줬더니 나중 배송이 꼬임). VRPTW는 **당일 전체를 한 번에 모아 야전역 최적**. B2B는 "즉시"보다 "당일 정시 배송"이 중요 → 일괄이 비즈니스에 더 맞춤.

해가 없을 때(infeasible) — 시간창만 단계적 완화 · 특정 일자에 시간창이 좁고 물량이 몰리면 솔버가 **infeasible**을 반환한다. 단순 예외 throw는 가용성을 해치므로, 다른 제약은 두고 **시간창만 ±30 → ±60 → ±90분**으로 단계적으로 풀어 재시도한다. *차량 추가 투입은 인력 자원 문제라 시스템 제어 밖, 모든 제약 무시 후 재계산은 SLA 약속 자체가 깨지므로 배제* — SLA 영향이 가장 작은 시간창부터 양보했다. 모두 실패하면 ROUTE_OPTIMIZATION_FAILED로 운영자에게 알리고, 스케줄러 레벨에서 10초 간격 3회 재시도한다.

CLICK TO ZOOM



실제 VRPTW 솔버 결과를 지도에 매핑한 경로 시각화. 각 색상이 한 담당자의 경로이며, 숫자는 방문 순서.

- ✓ 5명 담당자별 색상 구분 — 같은 색끼리 묶인 노드가 한 담당자의 하루 동선
- ✓ 방문 순서 표시(① ② ③ ...) — 솔버가 결정한 실제 순회 경로(sequence)
- ✓ 허브 출발 → 업체 순회 → 허브 복귀 — VRP의 전형적 라우트 구조가 그대로 출력에 반영

08 · KEY CONTRIBUTION ④

CONTRIBUTION #4

짧고 잦은 임계구역엔 비관적 락 — seq 채번 race condition 해결

경력의 동시성 학습 → 스터디 발표 → 본 프로젝트 적용. 3단계 학습 곡선의 매듭

P·배송담당자 등록 시 "최대 seq 조회 → +1 저장" 사이 동시 요청이 끼면 **Read-Modify-Write race** → 같은 seq가 두 번 발급.

A· `@Lock(LockModeType.PESSIMISTIC_WRITE)` 로 최대 seq row를 select for update. *대안 검토: 낙관적 락은 어차피 매번 충돌하는 채번엔 재시도 비용만 누적, 분산 락은 단일 인스턴스 토폴로지엔 과함* → "충돌 잦고 짧은 임계구역"엔 비관적 락이 최적이라 판단.

R· 동시 등록 요청에서도 seq 유일성 보장. 재시도 로직 없이 **DB 레벨에서 차단**. 추가로 락 타임아웃 3초를 명시해 장기 트랜잭션·데드락 시 `LockTimeoutException` 으로 빠른 실패 처리 — 무한 대기로 인한 스레드 점유 차단. 동시 등록 시나리오 단위 테스트로 seq 유일성을 검증했다.

CODE `JpaDeliveryManagerRepository.java` · `@Lock+timeout 3000`

REJECTED · 낙관적 락

버전 충돌 → 재시도

채번은 매번 같은 row를 만짐 → 거의 항상 버전 충돌 발생 → 재시도 비용만 누적되고 처리량 저하.

REJECTED · 분산 락

Redis · ZooKeeper

단일 인스턴스 배포 토폴로지엔 오버엔지니어링. 외부 의존성도 늘어남.

CHOSEN · 비관적 락

SELECT ... FOR UPDATE

임계구역이 짧고 충돌이 잦음 → 락 대기 부담은 작고 충돌 차단 효과는 큼. 재시도 로직 없이 DB 레벨에서 차단.

```
@Lock(LockModeType.PESSIMISTIC_WRITE)
@QueryHints({@QueryHint(name = "jakarta.persistence.lock.timeout", value = "3000")})
@Query("select dm from DeliveryManager dm "
      + "where dm.hubId = :hubId order by dm.seq desc")
Optional<DeliveryManager> findTopByHubIdOrderBySeqDesc(UUID hubId);
// → SELECT ... FOR UPDATE - 동시 요청은 대기 후 순차 처리, 3초 초과 시 LockTimeoutException
```

3단계 학습 곡선 연결 — 전 회사의 비동기 다운로드 race condition을 해결하면서 "정확히 어떤 락이 어느 상황에 맞는지" 몰랐던 게 학습 동기. 부트캠프 스테디에서 낙관적/비관적/분산 락 트레이드오프를 자칭 발표. 본 프로젝트에서 "충돌 잦고 짧은 임계구역엔 비관적 락"을 실제로 적용 — 한 사이클 연결.

09 · DEPLOYMENT · INFRA

배포 인프라 — IaC 한 번으로 AWS + Cloudflare 전 구간 프로비저닝

16개 컨테이너 규모의 MSA를 전시·데모용으로 월 ~\$14에 운용하기 위해, 인프라 전체를 Terraform 단일 코드베이스(IaC)로 선언하고 GitHub Actions + OIDC로 빌드·배포를 자동화했습니다. "비용 · 보안 · 운영부담"을 판단 기준으로, 매니지드 오케스트레이션 대신 단일 EC2 + Cloudflare Tunnel 조합을 의도적으로 선택했습니다.

월 ~\$14

비용 최적화

ALB/EIP 제거 · 평일 09~21시만 자동 가동
(24/7 대비 ~64%↓)

keyless

OIDC 기반 CI/CD

장기 액세스키 0개 · 임시 자격증명으로 9개
이미지 push

1× apply

IaC 단일 적용

VPC-EC2-RDS-ECR-IAM-Scheduler +
Cloudflare까지 선언적 관리

Terraform IaC + OIDC 키리스 CI/CD + Cloudflare Tunnel 무포트 노출

매니지드 과투자 대신 "전시 목적에 맞는 최소 비용 · 최소 공격면" 아키텍처를 직접 설계·구축

CI · GitHub Actions — `develop` push 시 9개 서비스를 **matrix 병렬 빌드** → ECR push(`:latest` , `:sha`). **OIDC**로 AWS 임시 자격증을 발급받아 장기 액세스키를 저장하지 않음. `type=gha` 레이어 캐시로 빌드 시간 단축.

IaC · Terraform — VPC(NAT 없는 퍼블릭 서브넷)·EC2·RDS(프리티어)·ECR·IAM(OIDC role)·EventBridge Scheduler·Lambda를 하나의 코드로 선언. **Cloudflare(Tunnel·DNS·SSL)까지 같은 `apply`** 로 생성하고, 터널 토큰을 EC2 `user_data`에 자동 주입.

네트워킹 · Cloudflare — ALB/EIP 없이 **Tunnel로 오리진을 노출**해 인바운드 포트를 전부 닫고(공격면↓), 무료 Universal SSL로 HTTPS 종단. 운영시간 외/주말엔 **Worker가 점검 페이지로 풀백**.

비용 운영 · EventBridge + Lambda — 평일 **08:40 start / 21:00 stop**으로 EC2·RDS를 자동 전원 제어, 전시 시간대만 가동해 비용을 절반 이하로 절감.

CODE  `build-push-ecr.yml` · OIDC `matrix`×9

 `iam.tf` · OIDC `role` 신뢰정책

 `user_data.sh.tftpl` · EC2 부트스트랩

 `cloudflare.tf` · Tunnel·DNS·SSL

 `scheduler.tf` · 평일 자동 전원

비용·보안 의사결정 — 대안별 트레이드오프

REJECTED · ECS / EKS

매니지드 오케스트레이션

전시 규모엔 과투자. 기존 `docker-compose`를 그대로 재사용하는 편이 훨씬 저렴하고 단순.

REJECTED · ALB + EIP

표준 인바운드 노출

ALB 월 ~\$22 + EIP 미사용 요금. 인바운드 포트를 열어야 해 공격면 증가.

CHOSEN · EC2 + CF Tunnel

단일 박스 + 터널

인바운드 포트 **0개**로 보안↑, ALB/EIP 비용 0, 무료 SSL. 전시 목적의 비용·보안 균형에 최적.

배포 파이프라인 & 런타임 토폴로지

push(develop) → GitHub Actions (OIDC · matrix ×9) → Amazon ECR
| pull

사용자 →https→ Cloudflare (Universal SSL + Worker 풀백) ▼

└Tunnel(무포트)→ EC2 t3.medium (앱9 + kafka/redis + cloudflared) → RDS (DB 8개)

▲ EventBridge + Lambda — 평일 08:40 start / 21:00 stop

기술 스택

영역	스택
Backend	Java 17 · Spring Boot 3.5.12 · Spring Cloud 2025.0.1 (Eureka · Gateway · OpenFeign)
Messaging	Spring Kafka · Outbox 패턴
Resilience	Resilience4j · Circuit Breaker · Retry
Data	PostgreSQL (database-per-service) · Redis · JPA · QueryDSL
Optimization	Google OR-Tools 9.12.4544 (VRPTW)
Infra (IaC)	Terraform · AWS (EC2 · RDS · ECR · IAM/OIDC · EventBridge · Lambda) · Docker Compose
CI/CD	GitHub Actions (OIDC · matrix build) → Amazon ECR
Edge / Network	Cloudflare Tunnel · Workers · Universal SSL

회고 — 잘한 것과 의도적 선택의 트레이드오프

프로젝트를 마치며 두 갈래로 정리. 무엇을 잘했고, 어떤 부분이 트레이드오프를 따진 의도적 선택이었는지. 각 선택의 한계와 다음 단계는 항목별 → 라인에 함께 적음.

✅ 잘한 것

단순 CRUD를 넘어 **이벤트 유실(Outbox)** · **최적화(VRPTW)** · **동시성(비관적 락)** 등 운영 수준 문제를 비즈니스 근거에서 출발해 직접 설계. 스터디에서 학습한 락 트레이드오프를 실제 적용. "검증=동기, 통지=비동기"의 통신 의도 분리가 일관되게 관철됨.

배송 컨텍스트를 한 서비스로 통합 (delivery + manager + route)

초기 설계엔 delivery / delivery_manager / delivery_route 3개 서비스로 분할했으나, 실제 도메인 분석 결과 **3개 도메인이 동일 트랜잭션 경계에서 함께 변경되는** 강한 응집성을 보임 → 별도 서비스로 분리하면 분산 트랜잭션 비용만 증가한다고 판단해 **delivery-service 한 컨텍스트로 통합 + 내부 도메인으로 분리.**

→ "같은 트랜잭션에서 변하는 것은 같은 서비스로" — DDD의 애그리거트 경계 원칙을 실제 적용한 사례

Outbox 스케줄러가 단일 인스턴스 전제

분산 스케줄러·ShedLock·리더 선출 등 옵션을 검토했으나, **각 마이크로서비스가 단일 인스턴스로 배포되는 현 토폴로지**에선 스케줄러 중복 실행이 발생 X → 분산 락 도입은 오버엔지니어링.

→ 수평 확장 시점엔 ShedLock(DB 락) 또는 컨슈머 측 역등 처리(이벤트 ID dedup) 추가 예정

full Saga 대신 Outbox 채택

다중 서비스 트랜잭션엔 Saga(보상 트랜잭션)도 후보였으나, 우리 케이스는 **단방향 통지·응답 불필요**라 full Saga의 복잡도가 과함.

→ 다중 단계 트랜잭션이 필요한 도메인에선 Saga가 정답 — 알고 있음

01 · OVERVIEW

LLM을 정량 평가하고, 안전하게 운영하는 백엔드

모놀리식 → MSA → LLMOps로 이어진 설계 성장의 마지막 매듭. RAG 답변 품질을 LLM-as-a-Judge로 정량 평가하고, Prometheus·Loki·Claude를 묶어 알림에 원인 분석과 복구 액션까지 자동 부착하는 시스템을 설계·구현했습니다. AI를 외부 API로 덧붙이는 대신 운영 모니터링 시스템의 일부로 통합한 점이 차별점입니다.

"LLM을 검증 가능하게 (Eval/Pairwise), 운영을 안전하게 (HTL·다층 방어) 만든다."

모의투자 플랫폼에서 도메인 사실성이 핵심인 RAG 챗봇 + LLM 기반 AIOps + 측정 가능한 관측 스택을 주도 설계.

- 2026 · 부트캠프 5인 · 담당: assistant · notification · monitoring 전담
- Java 17 · Spring AI 1.0 · pgvector · Kafka · GCP

2.38 → 4.04

faithfulness 향상

RAG 모델 교체 (LLM-as-a-Judge 점수 기반)

64.3% → 8.3%

환각률 -56pp

faithfulness < 3 비율

< 1분

MTTD

ServiceDown: scrape 15s x for 1m

74% ↓

캐시 히트 응답시간

3.68s → 0.95s (3.9배) · LLM 생성 호출 스킵

02 · SERVICE OVERVIEW

ants-camp — 재미배움캠프 · 가상 주식 투자 대회 플랫폼

실제 주식 데이터를 기반으로, 가상 자산으로 투자 대회에 참여하고 수익률 경쟁으로 순위를 겨루는 모의 투자 플랫폼.

사용자는 한국투자증권 API로 가져온 실시간 시세를 보며 모의 매매를 진행하고, 매니저가 만든 대회 규칙(거래 시간·종목 제한·시드머니 등)에 따라 전략 경쟁을 합니다. 대회 종료 시점의 평가 자산 기반 수익률로 순위·티어를 산정하며, 단순 모의 투자를 넘어 실시간 랭

킹 · AI 챗봇 · LLM 기반 운영 알림 · MSA 확장 구조까지 실제 서비스 수준의 경험을 목표로 설계했습니다.

서비스 6대 핵심 기능

01 · AUTH

회원 · 권한 관리

JWT 인증 + 사용자/매니저/관리자 RBAC. 매니저는 관리자가 등록된 계정으로만 활동.

02 · TRADING

가상 주식 매매

TradingView 실시간 조회 + 한국투자 API 기준가로 시장가 즉시 체결. 대회별 거래 시간·종목 제한 검증.

03 · COMPETITION

투자 대회 시스템

매니저 주도 대회 생성. 거래 규칙·참가 인원·시드머니 설정. 한 사용자가 여러 대회 동시 참가 가능.

04 · RANKING

실시간 랭킹 · 티어

주기적 수익률 계산 + Redis 캐싱. 종료 시 1·2·3 등 발표 + TOP 10% 상위 티어 자동 산정.

05 · AI ASSISTANT * 담당

RAG 기반 챗봇 + 품질 평가

FAQ·약관·매매규칙을 벡터화해 의미 검색. LLM-as-a-Judge로 답변 품질 정량 측정.

06 · NOTIFICATION * 담당

통합 알림 + 모니터링

메트릭·로그 자동 수집 + LLM RCA → Slack HITL 액션. 중복 알림 SUPPRESSED 처리.

03 · DESIGN GOALS

설계 도전 과제와 핵심 기여

핵심 도전 과제

- RAG 답변의 사실성(faithfulness) 정량 측정 — 정량 점수·승률로 모델 결정
- LLM 평가의 2대 편향 차단 — self-preference bias(Judge가 자기 출력에 후한 경향) + position bias(Pairwise A/B 위치에 따른 편향)를 코드 레벨에서 모두 차단
- 단순 알림을 "원인 + 권장 조치"로 격상 — 운영자 컨텍스트 수집 단계 제거
- LLM 자동 실행의 위험 — 인프라/PII/위변조의 다층 안전장치 필요
- 토이 프로젝트의 한계 — 측정 가능한 관측 시스템 자체를 차별점으로

핵심 기여 (개인)

- RAG 파이프라인 + LLM-as-a-Judge 3축 채점 + Pairwise 시스템
- Self-preference + Position bias 코드 레벨 차단 + Judge 2종 교차
- Alertmanager → Redis dedup → Claude RCA → Slack HITL 파이프라인
- Defense-in-Depth: 인프라 보호 2중 차단 + HMAC-SHA256 + PII 마스킹
- 관측 스택 주도 구축 — Prometheus/Loki/Promtail/Grafana/Alertmanager + alert를 7종 `for:` 차등
- RAG 응답 pgvector 의미 캐시 — 히트 시 latency 74%↓ · LLM 호출 스킵


04 · ARCHITECTURE

TO-BE 아키텍처 — GCP 5-VM 분리 토폴로지


Google Cloud Platform 위에 역할별 VM 5개 그룹으로 분리 배포합니다. APP VM(서비스 컨테이너) · Redis VM(랭킹 캐시·dedup) · Monitoring VM(관측 스택 단독) · Infra VM(Config·Eureka) · Kafka VM(이벤트). 외부 의존성(Vercel 프론트 · 한국투

자증권 API/WebSocket · 네이버 뉴스 · Cloud SQL · GCP Container Registry)은 GCP 경계 바깥에서 통신. AI Assistant(녹색)와 Notification(주황) 두 흐름이 동일 인프라를 공유합니다.

위 구성은 발표 시점의 아키텍처입니다. 발표 종료 후 운영 비용을 줄이고자 백엔드·프론트엔드 전체를 OCI 단일 인스턴스(Docker Compose + Nginx)로 직접 마이그레이션했고, 현재 라이브 데모가 그 위에서 동작합니다.



역할별 VM 토폴로지. 두 흐름의 단계별 상세는 아래 시퀀스 다이어그램 참고.



② Notification 흐름 — 이상 탐지에서 Slack 승인까지



설계 의사결정과 근거

결정	대안	선택 이유 — 정량 가정 · 확장 계획 포함
역할별 VM 5개 분리	단일 VM 통합 · K8s 클러스터	학습/포트폴리오 환경엔 K8s가 과함. 단일 VM은 SPOF-자원 경합 위험. 역할별 분리로 장애 격리와 자원 독립성 확보 . 운영 시 GKE로 단계적 이행 가능.
pgvector	Pinecone · Milvus	문서 수 수천 건 · QPS 한 자릿수 가정엔 cosine + IVFFlat로 p95 충분. 수십만 건 또는 멀티 테넌시 시점에 외부화 검토.
Spring AI + 모델명 라우팅	provider별 SDK 직접 호출	LLM(OpenAI/Claude/Gemini)을 Port 뒤로 추상화 → 모델 교체 시 application 무수정. Pairwise 비교 실험 자유로움.
Claude Haiku (장애 분석)	Opus · Sonnet	알림은 빈도 높고 빠른 요약이 관건 → Opus 대비 약 1/10 비용 , max_tokens 2000.
Human-in-the-Loop	LLM 전자동 실행	운영 컨테이너를 건드림 → AI는 추천까지, 실행은 사람 클릭 . 자동화 효율과 인간 판단 안정성 사이의 균형.
Reconciler(@Scheduled)	메시지 큐 (DLQ)	인제스트 동시성 분당 수십 건 가정엔 60초 주기 보정으로 SLA 만족. 분당 수백 건 이상 시 Kafka DLQ 전환.
단일 인스턴스 → 분산 락 생략	ShedLock · 리더 선출	각 서비스 단일 인스턴스 배포 토폴로지 → 스케줄러 중복 실행 자체 발생 X. 수평 확장 시 ShedLock + 컨슈머 먹등 처리.

CONTRIBUTION #1

LLM 답변 품질을 "감"이 아닌 "점수"로 검증 — 정량 평가 파이프라인

모델 교체 결정의 정량적 근거 확보. faithfulness 2.38 → 4.04, 환각률 64.3% → 8.3%, Pairwise 6승 0패

P · 대다수 RAG 프로젝트는 답변 품질을 "느낌"으로 판단하고 모델 교체를 "감"으로 결정 → 품질 회귀(regression) 위험을 막을 정량 체계 필요. 특히 LLM 평가의 가장 알려진 함정 **self-preference bias**(LLM이 자기 출력에 더 후한 경향, 연구로 보고됨)가 차단되지 않으면 평가 결과 자체가 신뢰 불가.

A · 검색 → 채점 → 비교 3단계로 정량 평가 파이프라인 구성. self-preference bias는 코드 레벨에서 차단 + Judge 2종 교차 검증으로 다중 방어.

검색 — pgvector 의미검색(topK×3 후 유사도 0.3-score-gap 0.8 컷오프 → 최종 topK=5)

채점 — Relevance / Faithfulness / ContextPrecision 3축 점수화

비교 — Pairwise A/B 위치 교차(앞쪽 편향 회피)

bias 방어 — Judge==생성모델이면 채점 skip · Judge temperature 0 · Judge 2종(claude-sonnet-4-6 + gpt-4o) 교차 검증

R · 점수·승률 기반으로 gpt-4o-mini → claude-haiku 교체. OpenAI 자사 gpt-4o조차 gpt-4o-mini를 낮게 평가 → 계열 편향 데이터로 반박.

CODE

EvalProcessor.java · Judge 채점·bias skip

PairwiseProcessor.java · A/B 위치 교차

RetrievalReranker.java · 검색 컷오프

★ 차별점 — 어떻게 차단했나 (3접 방어)

① BIAS BLOCK

Self-preference 코드 레벨 차단

Judge 모델 == 응답 생성 모델이면 채점 자체를 **skip**. 자기 출력에 후한 경향을 회피.

② CROSS

Judge 2종 교차 검증

claude-sonnet-4-6 + gpt-4o
양쪽 모두 돌려 한 모델에 결정 의존 X.
OpenAI 자사 gpt-4o조차 gpt-4o-mini를 낮게 평가.

③ PAIRWISE

A/B 위치 교차 비교

A/B 위치를 교차해 **양방향 비교** → 위치 편향(앞쪽 유리)까지 회피. 결과: 6승 0패.

```
// EvalProcessor.judgeAndSave()
if (judgeModel.equalsIgnoreCase(ragQuery.getLlmModel())) {
    log.warn("Self-preference bias 방지: skip. model={}", judgeModel);
    return;
}
```


결과 — 데이터 기반 의사결정

지표	GPT-4O-MINI (N=28)	CLAUDE-HAIKU (N=12)
faithfulness	2.38	4.04
relevance	2.38	4.00
contextPrecision	2.32	3.92
환각률 (faith < 3)	64.3 %	8.3 %
Pairwise (A/B 교차)	0승	6승 0패 (TIE 0)

표본 40건은 통계적 검정력 충분치 않으나 ① 두 Judge 동일 방향 ② Pairwise 동일 방향 → 방향성 견고, 정밀화 시 골든셋 200건+ 확대 및 사람 평가자 inter-rater agreement 측정으로 Judge 신뢰도 자체 검증 계획.

평가 대상이 된 실제 RAG 챗봇 UI

RAG · 출처 표시



위 정량 평가 시스템(LLM-as-a-Judge · Pairwise)의 평가 대상이 된 사용자 챗봇 화면. 응답에 더해 참조 문서의 출처를 함께 표시해 사용자가 근거를 직접 확인할 수 있도록 설계했습니다.

- ✓ 질문 → 응답 → 출처 가이드 3단계 표시 — "전용 계좌는 언제 발급받을 수 있죠?" 질문에 RAG로 검색한 가이드 문서 기반 답변 생성
- ✓ 출처 칩 클릭 → 우측 패널에서 참조한 가이드 문서의 주요 내용 미리보기
- ✓ "가이드 상세 페이지로 더 보기" 버튼 → 전체 문서 페이지로 이동, 답변의 근거를 원문까지 추적 가능
- ✓ 세션 기반 대화 이력 관리 — 좌측 "문의 목록"에서 이전 대화 재조회 (세션 제목은 마지막 메시지로 자동 설정)

CONTRIBUTION #2

측정 불가능한 운영을 측정 가능한 운영으로 — 관측 스택 주도 구축

MTTD < 1분 · alert 룰 7종 차등 설계 · 반복 알림 LLM 비용 0

P · 토이/부트캠프 프로젝트는 측정 시스템 부재로 정량 수치를 못 남기는 경우가 많음. "측정 가능한 시스템을 처음부터 만들었다"는 것 자체가 차별점이며, alert 룰 설계 역시 노이즈와 심각도를 함께 고려해야 함.

A · 관측 스택을 주도 구축하고 alert 룰 7종을 `for:` 지속조건으로 차등 설계 — "터지면 큰가(심각도) × 자주 출렁이나(노이즈)"를 함께 반영.

수집 — Prometheus(15s scrape · 10 job) + Promtail(docker_sd_configs 컨테이너 자동 발견)

저장 — Loki(로그) · Prometheus TSDB(메트릭)

시각화 — Grafana provisioning IaC(대시보드 코드 관리)

알림 — Alertmanager + 룰 7종 차등 설계(아래 표)

R · MTTD < 1분, 반복 알림 LLM 비용 0(dedup). SPOF 해소 fallback까지 완비.


CODE [alert-rules.yaml](#) · 룰 7종 for: 차등 [alertmanager.yaml](#) · match_re fallback

[promtail.yaml](#) · docker_sd

[monitoring/](#) · 스택 전체

룰	임계 / FOR	심각도	근거
ServiceDown	up == 0 / 1m	critical	scrape 15s × 4회 연속 실패라야 발동 → 순간 끊김과 구분
ConnPoolPending	> 3 / 1m	critical	대기 자체가 고갈 신호 → 가장 짧게
HighCPU	0.8 / 2m	critical	throttling 시작 구간, 100% 직전 여유
HighMemory · ConnPoolNear · HttpError	/ 2m	warning	스파이크와 추세 구분 가능한 지점
HighGcOverhead	0.1 / 5m	warning	단기 변동 잦아 가장 길게

★ SPOF 해소 — notification-service 자기 장애 시 Alertmanager match_re (라벨 정규식 매칭으로 알림 라우트 분기) fallback으로 Slack 직통(LLM 분석 없는 단순 텍스트로 알림 보존).



"측정 가능한 시스템을 만들었다"의 직접적 증거. 좌측은 서비스 대시보드(Prometheus 메트릭), 우측은 로그 대시보드(Loki 집계)로 메트릭과 로그를 Grafana 단일 UI에서 통합해 운영자가 화면을 오가는 수고를 덜었습니다.

- ✓ 핵심 게이지(좌상단): CPU 사용률 0.0838% · JVM Heap 9.54% — 실시간 상태를 게이지로 즉시 가독
- ✓ 시계열 패널 다수: CPU/메모리/HTTP 응답 시간/요청 수/스레드/GC/JVM CPU 사용률 등 서비스 헬스의 다축 추적
- ✓ 로그 통합 뷰(우측): notification-service의 INFO/WARN 로그 실시간 스트림. 로그 라벨링으로 컨테이너별·서비스별 필터링 가능

왜 PGAL Stack인가 — 모니터링 도구 선택 근거

MSA 환경의 주요 비기능 요구는 장애 추적·실시간 메트릭·중앙 집중 로그·자동 알림입니다. ELK · CloudWatch · Datadog 등 후보를 운영 비용 · 의존성 · 우리 규모 적합성 세 축으로 비교한 결과, **Prometheus + Grafana + Alertmanager + Loki + Promtail**(이하 PGAL)이 적절하다고 판단했습니다.

ELK Stack

Elasticsearch + Logstash + Kibana

✓ 강력한 Full-text 검색 · 대규모 로그 분석 · Kibana 시각화 우수

✗ Elasticsearch 메모리 사용량이 매우 큼 · Logstash 리소스 무거움 · 운영 복잡도 높음

판단: 우리는 Kubernetes 규모의 초대형 시스템이 아니고, 로그 분석보다 장애 추적이 더 큰 목적. Docker 기반 경량 MSA엔 과한 구성.

REJECTED
(over-spec)

CloudWatch

AWS managed

✓ AWS 서비스와 높은 통합성 · 별도 서버 운영 불필요 · 자동 스케일링

✗ AWS 의존성 증가 · 로그 저장 비용 누적 · 멀티 클라우드 대응 어려움

판단: 본 프로젝트는 GCP + 로컬 Docker 기반으로 운영 — 특정 클라우드 종속 회피.

REJECTED
(vendor lock-in)

Datadog

SaaS APM

✓ SaaS 구축 쉬움 · UI/UX 우수 · 로그+메트릭+트레이싱 통합 APM

✗ 비용이 높음 · 데이터량 증가 시 과금 부담 · SaaS 의존성

판단: 학습/포트폴리오 환경에서는 운영 비용 최소화가 중요해 부적합.

REJECTED
(cost-prohibitive)

PGAL Stack

Prometheus + Grafana + Alertmanager + Loki + Promtail

✓ MSA 사실상 표준(Prometheus) · Spring Boot Actuator 연동 용이 · ELK 대비 경량(Loki) · Grafana 단일 대시보드로 메트릭+로그 통합 · Docker SD로 컨테이너 자동 발견 · 전부 오픈소스로 비용 0

판단: 우리 규모(Docker 기반 MSA · 5인 팀 · 학습/데모 환경)에 정확히 맞는 균형. 운영 가시성을 확보하면서도 운영 부담을 최소화.

CHOSEN
★

5개 도구 각각의 역할



Prometheus

시계열 메트릭
scrape 15s



Grafana

통합 대시보드
IaC provisioning



Alertmanager

조건 기반 알림
Slack 라우팅



Loki

경량 로그 저장
라벨 인덱싱



Promtail

컨테이너 로그
Docker SD

도구	선택 이유 (한 줄)	활용 목적
Prometheus	MSA 사실상 표준 · Spring Boot Actuator 연동 용이 · 시계열 저장 최적화 · PromQL	CPU/Memory/API 응답시간/에러율/요청수 추적
Grafana	다양한 데이터 소스 + Loki/Prometheus와 높은 호환 + 대시보드 자유도	서비스별 메트릭 시각화 · 운영 대시보드 · 장애 실시간 확인
Alertmanager	Prometheus 자연스러운 통합 · 조건 기반 · Slack 연동 용이	임계치 초과 → Slack 알림 · API Error Rate 증가 감지
Loki	Elasticsearch 없이 로그 저장 · 라벨 인덱싱으로 비용 절감 · Docker 궁합	서비스별 중앙 로그 · 장애 로그 분석 · Trace ID 요청 추적
Promtail	Docker 로그 수집 단순 · Loki 공식 연동 · 설정 단순	컨테이너 로그 수집 · 서비스 라벨링 · Loki로 전달

📦 CONTRIBUTION #3

단순 알람을 넘어 원인 분석을 전달 — LLM 기반 AIOps (Human-in-the-Loop)

MTTR 단축 + AI 자동화의 안전성을 사람 클릭으로 통제. 운영자의 컨텍스트 수집 단계 제거

P · Prometheus → Slack 단순 알람은 "임계값 초과" 사실만 전달 → 운영자가 Grafana-터미널을 왕복하며 원인 추적에 시간 소요(MTTR의 대부분). 동시에 LLM 자동 실행은 운영 컨테이너를 건드리므로 위험.

A · Alertmanager webhook부터 Slack 메시지까지의 파이프라인을 **dedup** → 컨텍스트 수집 → **LLM 분석** → **HITL 액션** 4단계로 구성. **AI는 추천** 까지, 실행은 사람 클릭이라는 안전선 확보.

dedup — Redis fingerprint(SET NX , TTL 1h)로 중복 알람 차단

컨텍스트 수집 — Prometheus(CPU/Heap/에러수/응답시간) + Loki(최근 10분 에러 로그) 자동 fetch

LLM 분석 — Claude(haiku)가 메트릭·로그 기반 RCA(원인 분석 + 권장 조치) 생성

HITL 액션 — Slack Block Kit으로 분석 + 복구 버튼 4종(restart / rollback / cache-clear / false-alarm) 동시 노출

R · 알람 수신 후 수 초 내 "근거 메트릭/로그 + 권장 조치" 자동 게시. **AI를 운영 모니터링 시스템의 일부로 통합.**


```
// Slack 3초 응답 제약 → @Async ACK 후 메시지 갱신
@Async("slackActionExecutor")
public void executeAndNotifyAsync(SlackActionCommand command) {
    trySlack("처리 중", () -> alertPort.markAsProcessing(...));
    ActionResult result = executeAction(...);
    trySlack("완료/실패 갱신", () -> alertPort.markAsHandled(...));
}
```

CODE NotificationApplicationService.java · dedup→RCA→HITL

SlackBlockBuilder.java · 복구 버튼 4종

ClaudeApiClient.java · LLM RCA

RedisDeduplicationAdapter.java · SET NX dedup



실제 Slack 채널에 자동 게시된 LLM 기반 장애 분석 메시지와 복구 버튼 클릭 후 스레드 갱신까지의 동작 흐름.

- ✓ AI 장애 분석 리포트 — antcamp-user HTTP 400 에러 발생 시점, 심각도(warning), 에러율(7건/5분)을 자동 포착
- ✓ 원인 분석 — 1순위 클라이언트 입력값 검증, 2순위 일시적 클라이언트 트래픽, 3순위 서버 상태 등 우선순위가 매겨진 분석 제공
- ✓ 복구 버튼 4종(빨강 박스 영역): 코드 롤백 · 캐시 비우기 · 서비스 재시작 · 정상 처리(false alarm) — 운영자가 상황에 맞게 선택
- ✓ 스레드 자동 갱신(우측) — 버튼 클릭 시 @Async ACK 후 "처리중 → 완료/실패"로 메시지 갱신. Slack 3초 응답 제약 해소
- ✓ Grafana 대시보드 / 로그 보기 바로가기 버튼으로 운영자의 컨텍스트 전환 비용 최소화

08 · KEY CONTRIBUTION ④

CONTRIBUTION #4

LLM이 운영 시스템을 만지는 위험을 다층으로 차단 — Defense-in-depth

장애 시나리오 3종에서 fallback 동작 검증 완료

P· LLM 제안 시스템은 ① 인프라 서비스 오작동(LLM이 gateway/kafka에 destructive action 권유), ② 외부 위변조 요청(공개 endpoint 노출), ③ LLM 입력으로의 PII/시크릿 유출 등 다층 위험을 동시에 가짐.

A· 세 위험에 각각 독립적 방어선을 둬 (아래 3겹).

R· 세 시나리오 모두 fallback 동작 검증 완료 — ① notification-service 자기 장애 시 Alertmanager `match_re` fallback으로 Slack 직통, ② LLM API 장애 시 단순 텍스트 fallback, ③ 비동기 ingest 실패 시 Reconciler 자가복구.

CODE `SlackSignatureVerificationFilter.java` · HMAC·replay·timing

`PromptUtil.java` · PII 마스킹

`NotificationProperties.java` · 인프라 화이트리스트

① INFRA PROTECTION

인프라 서비스 2중 차단

gateway·kafka 등 `infrastructureJobs` 는 SlackBlockBuilder에서 버튼 자체 미노출 + `executeAction` 진입 시 화이트리스트 차단. API/payload 조작 우회까지 방어.

→ 두 겹 중 한 겹이 뚫려도 다음 겹이 막음

② SLACK FORGERY

위변조 · Replay · Timing 공격 방어

공개 endpoint에 전용 필터: **HMAC-SHA256 서명 검증** + timestamp 5분 초과 거부(replay) + `MessageDigest.isEqual` constant-time 비교(timing attack). body는 `CachedBodyRequest` 래핑.

→ 외부 위변조 요청 원천 차단

③ PII MASKING

LLM 입력 민감정보 마스킹

token · password · secret · bearer → [REDACTED], 이메일 → [EMAIL], 로그 4000자 제한. 외부 LLM 호출 직전 최종 검증.

→ 시크릿/PII 외부 API 유출 방지

트리블슈팅 — 원인을 윗단까지 파고든 사례

"외부 호출 때문에 트랜잭션이 길어졌다"는 표면적 설명에서 멈추지 않고, 커넥션 풀 → 톰캣 워커 스레드 → 세션 한계까지 원인을 윗단으로 추적한 사례들.

#01 · LLM 호출 중 DB 커넥션 점유 → 풀 고갈 위험

트랜잭션 경계 분리

현상 · 가설

- RAG 응답 생성은 평균 수 초 소요
- 유저메시지·봇메시지 저장을 단일 @Transactional 로 묶으면 LLM 응답 대기 내내 HikariCP 커넥션 점유
- 동시 요청 시 풀 고갈 → 톰캣 워커 스레드까지 블로킹 → 전체 타임아웃

원인 분석 (WHY → WHY)

- LLM 호출이 트랜잭션 안 → 커넥션 점유
- 커넥션 풀 고갈 → 톰캣 스레드도 트랜잭션 잡은 채 블로킹
- 스레드 풀 한계 도달 → 새 요청 거절
- 풀 확장은 근본 해결 X — 요청량 늘면 다시 고갈

해결 & 검증

- 3구간 분리: 유저메시지 저장(T1) → LLM 호출 (트랜잭션 없음) → 봇메시지 + COMPLETED(T2)
- omin 프로젝트 트랜잭션 경계 분리 교환을 LLM 호출에 그대로 재사용
- 측정 후속 계획: Micrometer
hikari_connections_active + llm_call_duration 게이지로 점유 시간 정량화 예정

CODE  RagApplicationService.java · T1→LLM(무TX)→T2

#02 · 비동기 ingest 부분 실패 → DB · 벡터 불일치(orphan)

먹등성 · 자가복구

현상 · 가설

- 문서 인제스트는 청킹 → 임베딩 → 저장 3단계
- 임베딩 단계 실패 시 청크는 DB에 남고 벡터는 비어 orphan 발생
- 재인제스트 시 단순 INSERT는 중복 벡터 생성

원인 분석

- 다단계 비동기 처리 + 부분 실패 시점이 불특정
- 재시도 시 먹등성 미보장 → 중복 가능
- 실패 작업이 PROCESSING 상태로 영구 잔존 위험

해결 & 검증

- 재인제스트 전 기존 벡터 선삭제(먹등성)
- DocumentReconciler 60s 주기로 10분 PROCESSING 감지
- 최대 3회 재시도 · PERMANENT 격리

CODE  DocumentReconciler.java · 60s 보정·3회·PERMANENT

#03 · 반복·유사 질문에도 매번 풀 RAG → 불필요한 LLM 지연·비용

pgvector 의미 캐시

현상 · 가설

- RAG 답변은 LLM 생성에 평균 수 초 소요
- FAQ·약관·매매규칙처럼 동일·유사 질문이 반복되는 도메인
- 매번 풀 RAG = 지연·비용 낭비

접근 — 의미 캐시

- 첫 턴 질문을 임베딩해 pgvector 의미 캐시 (p_response_cache) 조회
- $1 - \text{cosine} \geq \text{threshold}$ & 미만료면 저장 답변 즉시 반환 → LLM·벡터검색 생략
- 미스 시 풀 RAG 후 적재(TTL config) · 첫 턴(히스토리 빈 상태)에서만 → 단발성 트래픽 최적

해결 & 검증

- 캐시 히트 0.95s — 미스(긴 답변 3.68s) 대비 74%↓ (3.9배)
- LLM 생성(2.41s) 자체를 제거
- 워크로드별 wall-time-LLM latencyMs 분리 측정(아래 표)

CODE  ResponseCacheAdapter.java · 의미 캐시 조회/적재  RagApplicationService.java · 첫 턴 캐시 흐름

구분	클라이언트 WALL-TIME (중앙값)	서버 LLM LATENCYMS
미스 — 긴 답변(100~185자)	3.68s	2.41s
미스 — 짧은 거절(82자)	2.82s	1.34s
캐시 히트	0.95s	LLM 호출 스킵

동시성 · 같은 응답 경로에서 동일 세션 동시 전송 시 seq 채번 race는 findMaxSeqForUpdate + @Lock(PESSIMISTIC_WRITE) 로 차단
— 락 선택 트레이드오프는 배송 담당자 seq 채번에서 상세히 다룬 동일 판단의 재적용.

10 · STACK

기술 스택

영역	스택
Backend	Java 17 · Spring Boot 3.5 · Spring Cloud (Eureka · Config · Gateway) · Spring AI 1.0
AI / LLM	LLM-as-a-Judge · Pairwise · pgvector · Claude (Anthropic) · OpenAI · Gemini (fallback)
Data	PostgreSQL + pgvector · Redis · Kafka
Observability	Prometheus · Grafana · Loki · Promtail · Alertmanager · Zipkin
Infra	Docker · Terraform · GCP · GitHub Actions

11 · RETROSPECTIVE

회고 — 의도적 선택과 진짜 아쉬운 점을 구분하다

프로젝트를 마치며 세 갈래로 정리. 무엇을 잘했고, 어떤 부분이 의도적 선택이었으며, 어디가 진짜 아쉬웠는지.

✓ 잘한 것

LLM을 붙이고 끝내는 대신 검증 가능한 시스템(Eval/Pairwise · bias 차단)으로, 운영을 안전하게(Human-in-the-Loop · 다층 방어 · 자가복구) 만든 것. 그리고 토이 프로젝트의 한계인 "측정 수치 부재"를 관측 스택 주도 구축으로 정면 돌파.

복구 액션이 단일 호스트 Docker socket 1:1

SSM · K8s rolling restart로 외부화하는 옵션도 검토했으나, **단일 호스트 데모 환경**에선 직접 호출이 더 단순·명료. 운영 복잡도 증가의 비용이 이득을 넘어선다고 판단.

→ 다중 인스턴스 시점엔 SSM/K8s API로 외부화 예정

Loki replication_factor=1 · retention 미설정

단일 VM 토폴로지에선 HA가 의미 없음 → 단순 구성 선택. 데이터 영속성도 데모 범위 안에서 충분.

→ 운영 환경 전제로는 다중 노드 + 보관 정책 도입

인증을 게이트웨이 헤더에 위임

모든 서비스에 JWT 검증을 중복 구현 vs 게이트웨이 단일 검증의 단순함을 비교한 결과 **부트캠프 규모엔 후자가 적절**.

→ 운영 환경엔 서비스 레벨 JWT 한 겹 추가가 정석 — 알고 있고 다음에는 그렇게 설계

분산 락 생략

각 서비스가 단일 인스턴스 배포 토폴로지에선 스케줄러 중복 실행 자체가 발생 X → ShedLock 도입은 오버엔지니어링.

→ 수평 확장 시점에 ShedLock + 컨슈머 먹통 처리 추가

진짜 아쉬운 것

더 챙겼어야 하는 부분

의미 캐시 임계값이 엄격 — 유효 hit율 한계

측정해 보니 코사인 ≈ 0.95 임계값이 사실상 **동일 문구만 통과**시켜, 같은 의도라도 표현이 다른 질문은 전부 미스(paraphrase hit율 0%). 캐시 히트도 $\sim 0.95s$ 소요(질문 임베딩 왕복 1회). 측정 자체도 단일 클라이언트·소표본 기준이라 동시성/부하 하 수치는 아님.

→ 임계값 **0.90~0.92 완화**(미묘하게 다른 질문에 오만한 위험과 트레이드오프) · 정규화 질문 exact-match 단축 경로 · 임베딩 캐싱 검토

01 · OVERVIEW

AI가 일하는 방식을 설계하는 것 — 하네스 엔지니어링

개발을 AI에게 일임하는 것이 아니라, AI가 이 코드베이스 규칙을 벗어나지 못하도록 통제·감독하는 체계를 설계합니다. AI의 결과물은 빠르고 그럴듯하지만 맥락을 모른 채 자주 틀리기에, antcamp (가상 주식 거래 MSA · 도메인 서비스 7개)에 규칙 문서(SSOT) · 자동 검토/테스트 스킴 · 가드레일을 둘러 AI의 출력은 사람의 검증을 통과해야만 코드베이스에 반영되도록 했습니다. 코드의 최종 판단과 책임은 항상 사람이 집니다.

harness engineering — AI를 통제·감독하는 체계를 엔지니어링

반복 타이핑만 AI로 처리하되, 무엇을·언제 참조할지, 무엇을 실행하면 안 되는지, 무엇을 반드시 검증할지를 사람이 못박습니다. AI가 단독으로 코드를 확정하는 일은 없습니다 — 모든 출력은 규칙·자동 검토·빌드 검증을 거쳐 사람이 최종 확인합니다. 도구(모델·CLI)는 빠르게 바뀌지만, 규칙 문서·검토 스킴·가드레일이라는 관리 체계는 프로젝트를 넘어 남습니다.

• SSOT 규칙 문서 3종 • 자동 검토·검증 A · B · C • 합격 판정은 사람이

02 · DEV CYCLE

개발 사이클 단계별로 도구를 나눠 쓴다

분석·구현·리뷰는 요구하는 판단이 다릅니다. 단계마다 도구를 분리하되, 설계·결정과 핵심 분기는 사람이 직접 운전하고 AI의 출력은 그 자리에서 검증합니다.

분석 · 설계

Claude Code

루트 CLAUDE.md 의 핵사고날 4레이어·네이밍 규약을 기준으로 호출 경로와 설계 대안을 교차 검증. 포트를 안쪽(application/domain)에 먼저 두고 어댑터를 infrastructure 에 두는 흐름을 그대로 따름.

구현 · 테스트

Claude Code · 서브에이전트

보일러플레이트·반복 작성에만 서브에이전트를 쓰고, 도메인 로직과 메인 흐름은 직접 작성·통제. AI가 낸 초안은 경계 조건·검증 기준을 다시 설계해 그대로 받지 않고 반드시 손본다.

리뷰

/revref · CodeRabbit

커밋 전 직접 만든 /revref 스킴이 컨벤션 위반을 점검(신규 파일·50줄+ 수정 시 자동), PR 단계는 CodeRabbit이 동일 원칙으로 한 번 더. 반복 지적은 규칙 문서로 흡수.

규칙을 단일 출처(SSOT) 문서로 주입한다

AI가 일관되게 일하려면 "무엇이 규칙인가"가 한 곳에 있어야 합니다. 세 문서가 서로를 참조하며 구조·규칙·절차를 나눠 가지고, CI 리뷰 봇(`.coderabbit.yaml`)과 동일한 기준을 공유합니다.

구조 · 컨벤션

CLAUDE.md

헥사고날 4레이어, 패키지·네이밍 표, 게이트웨이 인증 흐름(`X-User-Id` 신뢰 경계), Config Server 외부화, `common` 모듈 규약.

코딩 규칙

coding-conventions.md

트랜잭션 범위·JPA 캡슐화·DDD/레이어 경계·MSA 경계·`record` VO·동시성/분산락·로깅 보안·`common` 재사용. 위반은 심각도로 분류.

절차

automation-workflow.md

코드 작업 후 자동 검토(A)·빌드/테스트/API(B)·Slack 보고(C) 워크플로우의 트리거와 흐름을 정의. "언제 무엇을 자동으로 할지"를 명문화.

심각도 체계 — 리뷰가 무엇을 막고 무엇을 권하는가

Request Changes 반드시 수정

- 아키텍처 경계 위반 — DDD/레이어/트랜잭션/이벤트 경계
- `@Transactional` 안에서 외부 API 호출(커넥션 점유)
- JPA 엔티티 `@Setter` / `@Data` — 상태 변경은 의미 있는 메서드로
- 1트랜잭션 1Aggregate · 분산 트랜잭션(2PC) 금지 → Kafka 최종 일관성
- 동시성 제어 누락 · 민감정보 평문 로그

Comment 개선 권장

- 성능 · 코드 품질 · 리팩토링
- VO/DTO/Event는 `record` · Strong Type VO(primitive obsession 회피)
- N+1 회피 — 연관관계 `LAZY` 기본, 필요 시 `fetch join`

코드베이스 특수 예외는 규칙으로 흡수한다

일반론이 이 코드베이스엔 안 맞는 경우, 왜 예외인지를 규칙 문서에 직접 박아 AI 리뷰가 같은 지적을 반복하지 않게 합니다. 예: "모든 `record` 의 compact constructor에 검증을 넣으라"는 일반 규칙에 대해 —

conventions §4 — 명문화된 예외

- 서비스 간 내부 이벤트 메시지 `record` 는 발행 측에서 검증되었다고 가정하므로 compact constructor 검증의 예외로 둔다.
- AI/리뷰 봇이 "검증 누락"으로 잘못 지적하지 않고, 의도한 설계임을 그대로 확인할 수 있다.

작업 단계에 맞춰 자동으로 도는 워크플로우 A·B·C

규칙은 "지켜야 한다"로 끝나지 않게, 작업이 끝나면 자동으로 검토·검증·보고가 돌도록 슬래시 스킴과 스크립트로 묶었습니다.

워크플로우	트리거	수단
A · 코드 작업 후 자동 검토	새 파일/메서드 추가, 50줄+ 수정, <code>common/</code> 변경	<code>/revref</code> 스킴
B · 빌드→테스트→API 실행	런타임 동작에 영향 주는 변경 완료	<code>/apitest</code> 스킴
C · 완료 후 Slack 보고	A/B 또는 주요 작업 완료	<code>notify-slack.sh</code>

A. `/revref` — 컨벤션 준수 자동 검토

`git diff` 변경분(`--context`)이나 지정 파일을 대상으로, **차원별 리뷰 에이전트**를 병렬 실행해 위반을 심각도와 근거(`conventions $N`)와 함께 보고합니다. 같은 일반론 지적이 반복되면 규칙 문서로 흡수합니다.

병렬 검토 차원 — ① 아키텍처/레이어/DDD(\$2,5,7) ② Spring/JPA 내부(\$1) ③ 동시성(\$6) ④ 타입 안정성·공통 모듈(\$4,9). `--context` 모드에 서는 정확성(`/code-review`)·보안(`/security-review`) 검토까지 통합해   + **파일:라인** + **근거** → **제안** 형식으로 종합합니다.

`/revref` 실행 결과 — 차원별 병렬 검토 종합

WORKFLOW A

● revref 결과 — notification-service 알림 상태별 카운트 API (8개 파일)

CLICK TO ZOOM

지적 사항

심각도: 
위치: —
문제: 없음 (머지 차단 사유 없음)
제안: —

심각도: 
위치: `NotificationStatusCountResponse.java:24`
문제: `total`을 4개 상태 하드코딩 합산(`pending+sent+failed+actionFailed`). 현재는 정확하나 `AlertStatus` 값 추가 시 `total`에서 조용히 누락 (3개 에이전트 독립 지적)
제안: `counts.values().stream().mapToLong(Long::longValue).sum()`로 맵 전체 합산

심각도: 
위치: `NotificationStatsQuery.java:14-17`
문제: 8-인자 `NotificationSearchCriteria`를 위치 인자 + `null` 리터럴 6개로 생성 → 빌드 변경 시 취약 (타입 달라 오버치는 컴파일 에러로 걸림)
제안: `criteria.forStats(severity, source)` 정적 팩토리 (선택)

심각도: 
위치: `NotificationController.java:93`
문제: (범위 밖·선제 이슈) 기존 `receiveSlackAction`이 Slack payload 전문 로깅
제안: `notificationId` 등 비민감 식별자만 로깅, 별건 처리

변경분을 차원별 에이전트가 병렬 검토해   심각도·파일:라인·근거(`conventions $N`)와 함께 보고한다.

B. `/apitest` — 빌드부터 게이트웨이 시나리오까지

1-2 · 빌드 · 단위

gradlew

`build -x test` → `test`. 실패 시 컴파일/테스트 원인을 요약하고 여기서 중단, 결과 저장 후 실패 보고.

3-4 · 인프라 · 시나리오

docker · *.http

게이트웨이 :8080/actuator/health 폴링 후 `scenario*.http`를 게이트웨이 기준으로 실행, 단계별 상태코드·본문으로 통과/실패 판정.

5 · 보존

tests/results

타임스탬프 폴더에 `summary.md` 표·요청·응답 저장. 토큰·시크릿은 마스킹, 결과물은 `.gitignore`.

apitest 결과 — notification-service 상태별 카운트 API

CLICK TO ZOOM

1) 빌드 :apps:notification-service:build -x test → SUCCESSFUL
2) 단위 테스트 :apps:notification-service:test → NO-SOURCE (해당 서비스 테스트 소스 없음)
3) 인프라 Postgres(pgvector) + Redis 컨테이너 + 로컬 bootJar(:8098) 경량 기동 → 실 DB(p_slack_messages)에 8건 시드. 게이트웨이 계약대로 X-User-Id/X-Role 헤더 직접 주입.
4) API 실행 - 8/8

#	케이스	엔드포인트	기대	실제	결과
01	필터 없음	/admin/stats	8/2/4/1/1	8/2/4/1/1	
02	severity=CRITICAL	...?severity=CRITICAL	3/1/1/1/0	3/1/1/1/0	
03	source=PROMETHEUS	...?source=PROMETHEUS	4/1/3/0/0	4/1/3/0/0	
04	두 필터 동시	...?severity=CRITICAL&source=PROMETHEUS	2/1/1/0/0	2/1/1/0/0	
05	결과 0건	...?severity=INFO&source=GRAFANA	0/0/0/0/0	0/0/0/0/0	
06	잘못된 enum	...?severity=BOGUS	400 INVALID_INPUT	400 INVALID_INPUT	
07	목록 일관성 (전체)	/admin?page=0	totalElements=8	8	
08	목록 일관성 (CRITICAL)	/admin?severity=CRITICAL	totalElements=3	3	

빌드·단위 테스트 후 게이트웨이 헬스 폴링 → 시나리오(.http)를 단계별 상태코드·본문으로 통과/실패 판정한다.

C. notify-slack.sh — 작업을 깨지 않는 보고

SCRIPTS/NOTIFY-SLACK.SH

```
# 성공/실패 + 제목 + 본문(또는 summary 파일)으로 Incoming Webhook 보고
scripts/notify-slack.sh --status success \
  --title "apitest: trade-service" \
  --file "tests/results/20260628_153000/summary.md"

# 웹훅 미설정 시 → 경고만 출력하고 정상 종료 (빌드/작업을 깨지 않음)
```

외부 전송이므로 처음에는 보고 대상·내용을 사용자에게 확인받고, 사소한 변경(문서/오타)은 보고하지 않습니다.

☆ # dev-report

● 메시지 📄 캔버스 추가 +



dev-report 앱 오전 1:00

오늘 ▾

apitest: notification-service 상태별 카운트 API

apitest: notification-service — 알림 상태별 카운트 API

- 대상: GET /api/notifications/admin/stats (신규) + 회귀: GET /api/notifications/admin
- 일시: 2026-06-29 00:56 (KST)
- 변경 파일: NotificationController, NotificationStatsRequest(신규), NotificationStatsQuery(신규), NotificationStatusCountResponse(신규), NotificationQueryService, NotificationRepository(port), NotificationRepositoryImpl, NotificationQueryRepository(GROUP BY 집계)

성공/실패·제목·요약을 Incoming Webhook으로 전송한다. 웹훅 미설정 혹은 슬랙 전송 오류 시 경고만 출력하고 작업을 깨지 않는다.

가드레일과 컨텍스트를 설계한다

생성을 빠르게 하되, 위험한 자동화는 막고(가드레일) AI가 틀린 맥락으로 추측하지 않게(컨텍스트) 합니다.

가드레일 — 무엇을 못 하게 하나

- 합격 판정은 사람이 — 검토·테스트는 자동화하되 통과 여부는 직접 결정, 🚫 항목은 반드시 수정 후 빌드로 재검증
- 외부 전송은 확인 후 — Slack 보고는 처음에 사용자 승인
- 시크릿·PII 마스킹 — 테스트 결과·로그에
JWT/ KIS_* / *_API_KEY / 비밀번호 평문 금지(\$8)
- 테스트 산출물(tests/results/)은 커밋 대상 아님
(.gitignore)
- 신뢰 경계 — 도메인 서비스는 JWT를 직접 검증하지 않고 게이트웨이가 주입한 X-User-Id 만 신뢰

컨텍스트 — 무엇을 언제 보게 하나

- SSOT 상호참조 — 세 문서가 서로를 가리켜 중복·표류 방지
- 설정 외부화 인지 — "이 레포에서 application.yaml 찾지 말 것", 실제 설정은 Config 레포(dev)
- 작업 유형별 참고문서 라우팅 — RAG 작업 → rag-architecture.md , 알림 작업 → aiops-architecture.md
- 휘발성 큰 정보(스키마·설정)는 문서에 박제하지 않고 그때그때 실측

왜 이렇게까지 하는가

AI 생성물은 빠르지만 이 코드베이스의 맥락을 모른 채 그럴듯하지만 틀린 코드를 자신 있게 내놓습니다. 그 실수가 코드베이스에 들어 오지 못하도록 규칙(SSOT)·자동 검토/검증·가드레일로 여러 겹의 관문을 두고, 사람은 생성이 아니라 감독과 최종 판단에 시간을 씁니다. AI는 빨라지되 사람의 통제 밖에서 코드를 확정하지 못합니다. 이 관리 체계는 모델·도구가 바뀌어도 남습니다.

AI에게 개발을 일임하지 않는다 — 통제하고 감독한다.